Gerenciamento Inteligente do Consumo de Energia

Anderson Felipe S. de Carvalho Zaú Júlio A. Galvão
João Paulo De Souza Medeiros João Batista Borges Neto
Luiz Paulo De Assis Barbosa

Resumo

Em uma sociedade conectada e que apresenta uma crescente demanda no consumo de eletricidade como a que vivemos, um gerenciamento adequado da geração, do fornecimento e do consumo de energia elétrica é fundamental para manutenção das relações e atividades dessa sociedade. Nesse projeto, fez-se uso de uma plataforma de aquisição de dados de consumo de energia, desenvolvida pela UFCG, e desenvolveu-se uma metodologia para análise desses dados.A metodologia desenvolvida usa, análise estatística para criação de perfis de consumo, bem como os algoritmos de agrupamento, *k-means* e mapas auto-organizáveis, juntamente com técnicas de regressão a fim prever problemas e detectar anomalias no consumo. Os resultados obtidos foram satisfatórios permitindo a criação do perfil e a classificação do consumo, minuto a minuto, nas categorias, baixo, esperado, acima do esperado e alarmes, para cada dia útil da semana e até para comportamentos distintos observados dentro de um mesmo dia. Analisando-se os resultados percebeu-se que, em média, considerando-se todos os dias da semana, 14,6% dos dados são classificados como acima do esperado ou alarmes. Apenas como alarmes, a proporção foi de 3.24% do total de dados, restando 85,4% nas categorias de consumo esperado ou baixo. ***Palavras-Chave***— Monitoramento de Consumo de Energia; Sistema de Alarme;

Sumário

1 Introdução **5**

2 Metodologia **6**
2.1 Detalhamento das Abordagens 6
2.1.1 Analise Estatística 6
2.1.2 Aplicação de Regressão e SOM para a definição dos Limiares 7
2.1.3 Descoberta de Comportamentos Utilizando SOM 7

3 Resultados e Discussão **8**
3.1 Análise Estatística 8
3.2 Análise por Modelos de Regressão 12
3.3 Descoberta de comportamentos via SOM 17
3.3.1 O Algoritmo SOM 17
3.3.2 Aplicação dos Mapas Auto-Organizáveis 18
3.4 Classificação dos exemplos dos grupos de comportamentos via regressão . . 20

4 Conclusão **23**

Lista de Tabelas

1 Informações resultantes do *k-means* com três faixas de consumo, conforme a Figura 2. 9
2 Informações resultantes do *k-means* com quatro faixas de consumo, conforme a Figura 3. 9
3 Porcentagens de classificação do total de dados nas faixas de consumo alta e muito alta via *k-means*. 16
4 Porcentagens de classificação dos dados usando os modelos de regressão. . . 16
5 Valores em *Watts* das médias dos limiares e dos limites de faixa da classificação via *k-means*. 16
6 Resultados para os grupos de comportamento, ilustrados nas Figuras 14. . 20

Lista de Figuras

1 Ilustração da metodologia geral. 6
2 Divisão dos dados em três faixas de consumo, baixo, médio e alto. 8
3 Divisão dos dados em quatro faixas de consumo, baixo, médio, alto e muito alto. 9
4 Ilustração dos histogramas do grupo de consumo baixo. 10
5 Ilustração dos histogramas do grupo de consumo médio. 11
6 Ilustração dos histogramas do grupo de consumo alto. 11
7 Ilustração dos histogramas do grupo de consumo muito alto. 12
8 Ilustração do estudo da variação do grau dos modelos de regressão. 13
9 Ilustração da metodologia para ajuste do modelo e criação do limiar, abordagem 1b. 14
10 Visualização da média dos exemplos, das faixas de consumo do *k-means*, $k = 4$, e dos limiares da regressão. 14
11 Visualização da classificação dos exemplos de acordo com os limiares da regressão. 15
12 Valores das médias dos limiares e os limites de faixa da classificação via *k-means* nos dias úteis da semana. 17
13 Ilustração do funcionamento do algoritmo dos Mapas Auto-Organizáveis. . 18
14 Ilustrações dos comportamentos no mapa. Em roxo está os pesos sinápticos, em pontos coloridos os exemplos agrupados. 19
15 Ilustração da classificação do 2º grupo da quarta-feira usando regressão. . . 20
16 Ilustração da classificação do 3º grupo da sexta-feira usando regressão. . . 21
17 Ilustração da classificação do dia 15/04/2019, pertencente ao 5º grupo da segunda, usando regressão. 21

1 Introdução

Uma das características do consumo de eletricidade pela sociedade é que a demanda por esse recurso apresenta uma tendência de crescimento. Isso é resultado do aumento da renda familiar, da eletrificação dos meios de transporte e aquecimento, da crescente demanda por dispositivos digitais, de conectividade, entre outros [1]. Outra característica é a maneira ineficiente em que esse consumo ocorre, o que o torna uma questão problemática historicamente tanto em âmbito nacional quanto global [2].

Devido às características mencionadas, o impacto econômico do consumo energético nos custos de operação dos diversos setores da sociedade, tais como o residencial, o industrial, o de serviços, o de transporte e o de geração de energia é bastante significativo. Portanto, sistemas de auxílio ao monitoramento e gerenciamento do consumo de eletricidade são ferramentas cada vez mais desejadas pelos gestores desses setores. Motivado por esse cenário, foi desenvolvido, pelo Laboratório de Automação e Processamento de Sinais (LAPS-UFCG), um dispositivo de aquisição de dados sobre o consumo de eletricidade e um sistema de armazenamento desses dados. Esse dispositivo, ao ser instalado em uma unidade de consumo, por exemplo, um prédio, coleta os valores de potência ativa e reativa consumida, bem como o fator de potência para cada fase do sistema elétrico. Com o sistema de aquisição concluído, uma colaboração entre o LAPS-UFCG e o Laboratório de Elementos do Processamento da Informação (LabEPI-UFRN) foi firmada. Dela surgiu uma iniciativa para desenvolvimento de um sistema de monitoramento e gerenciamento de consumo energético, da qual resultou este trabalho.

O presente trabalho apresenta os resultados obtidos por meio do processamento dos dados de uma unidade de consumo, o prédio do LAPS-UFCG, coletados por esse sistema. Utilizando técnicas de inteligência artificial, o objetivo era responder as seguintes perguntas: i) Qual o perfil de consumo dessa unidade? ii) Como identificar consumos fora do padrão entre o final das atividades do laboratório que ocorre às 23:00 até o reinício das atividades por voltas das 8:00 horas do dia seguinte?

Para responder a primeira questão, os dados da série temporal correspondente à potência ativa de uma das fases do sistema elétrico foram eleitos como nosso objeto de estudo. Para responder a segunda questão, um recorte da série temporal mencionada compreendendo o intervalo entre as 20:00 e as 23:59 foi considerado.

A exploração estatística dos dados, juntamente com a aplicação de técnicas de agrupamento, *k-means* [3] e Mapas Auto-Organizáveis (*Self-Organizing Maps*, SOM) [4], e regressão linear [5], expôs várias possíveis características sobre o perfil de consumo, tais como periodicidade, faixas de consumo, comportamentos de consumo distintos (considerando desde a época do ano até um dia específico da semana) e anomalias contínuas e repetitivas, com isso foi possível a criação de modelos de consumo e a definição de limiares para classificação dos dados de consumo como: baixo, esperado, acima do esperado e alarme.

O presente artigo tem por intuito o estudo e emprego de técnicas de modelagem, predição, agrupamento e classificação de dados para extrair informações dos dados de consumo e produzir um sistema inteligente, especialista, de monitoramento e gerenciamento do consumo de eletricidade.

2 Metodologia

De forma geral, a metodologia empregada neste trabalho consiste em quatro etapas, com três abordagens diferentes para a etapa final, conforme ilustrado na Figura 1. A primeira etapa consiste no pré-processamento dos dados de consumo, o que permite conhecer, manipular e adequar a base de dados para a aplicação subsequente dos algoritmos de agrupamento, de regressão e de análise estatística. A segunda etapa corresponde à aplicação do algoritmo *k-means* aos dados pré-processados fornecendo uma separação preliminar dos dados em faixas de consumo. A terceira trata da seleção de subconjuntos ou cortes dos dados, considerando ou não as faixas de consumo, para estudos posteriores mais detalhados do recorte em questão. A quarta etapa contém três abordagens, a abordagem **4.a** corresponde à análise estatística desses recortes produzindo perfis de consumo, localização de picos de consumo, descoberta de sazonalidades, entre outras características. A abordagem **4.b**, diz respeito à criação de modelos e à computação de limiares de classificação para esses recortes, usando regressão e SOM, bem como o posterior uso desses limiares e modelos na classificação em faixas de consumo e alarmes. A abordagem **4.c** compreende o uso de SOM para descobertas de perfis de comportamento e seu posterior uso para classificação/marcação (*labeling*) dos exemplos da base de dados de forma automática. Essa etapa visa dar suporte ao uso futuro de algoritmos de aprendizado de máquina supervisionado na análise desses dados.

Figura 1: Ilustração da metodologia geral.

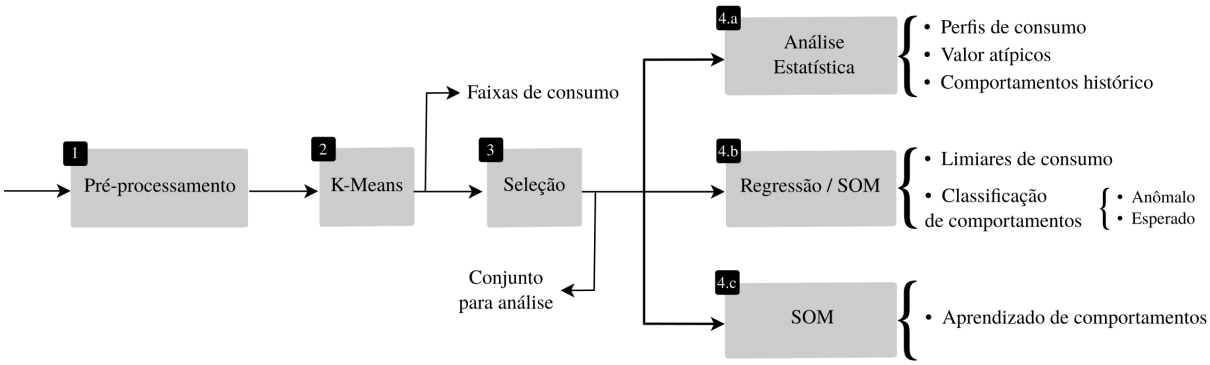

Fonte: próprio autor.

2.1 Detalhamento das Abordagens

2.1.1 Analise Estatística

Este procedimento, abordagem **4.a** da quarta etapa da Figura 1, trata da análise inicial dos dados por meio de histogramas. Isso foi realizado para, conhecer o comportamento da entidade consumidora avaliada e para criar o seu perfil de consumo. Os dados foram analisados considerando a frequência de consumo por hora, por dia da semana, por mês, entre outros.

2.1.2 Aplicação de Regressão e SOM para a definição dos Limiares

Este procedimento, abordagem **4.b** da Figura 1, diz respeito à criação de modelos e à computação de limiares de classificação para os recortes de dados nos quais é aplicado. O recorte, nessa etapa, corresponde aos dados de consumo obtidos minuto a minuto no intervalo das 20:00 às 23:59 para uma das fases do sistema elétrico, durante os dias úteis da semana. Portanto, a entrada para o cálculo dos modelos consiste em um conjunto de exemplos com 240 valores da potência ativa consumida no intervalo mencionado.

Para criação dos modelos, foram selecionados dois algoritmos, regressão e SOM. Os modelos de regressão foram computados variando o grau da regressão no intervalo de 1 a 5. Baseada na análise do erro e da complexidade, ambos realizados de forma empírica, foram selecionados os modelos de grau 4 como base para determinação dos limiares. No caso dos modelos criados usando os SOM, os dados de treino do recorte foram aplicados a um mapa como uma matriz quadrada de ordem três e o conjunto de modelos obtidos corresponde aos pesos sinápticos do grupo similarmente correspondente dessa rede. Na aplicação de SOM a métrica de similaridade escolhida foi a distância euclidiana. Tanto para a regressão quanto para o SOM, modelos independentes para cada dia útil da semana foram criados.

Os limiares são computados adicionando o vetor de erro, computado usando a raiz do erro quadrático médio (RMSE), aos vetores dos modelos. Desta forma é possível obter 4 regiões distintas abaixo do modelo de regressão, entre o modelo de regressão e o limiar, acima do limiar até um horário especificado e acima do limiar após o horário especificado. Com isso, os dados podem ser classificados como: consumo baixo, consumo esperado, consumo acima do esperado e alarme, conforme os valores de consumo se localizem na primeira, segunda, terceira ou quarta região respectivamente. Para as classificações acima do esperado e alarme, as quais dependem da especificação de um horário, este foi fixado às 23:00 pois se trata do horário oficial de término das atividades acadêmicas.

2.1.3 Descoberta de Comportamentos Utilizando SOM

Este procedimento, abordagem **4.c** da Figura 1, compreende o uso dos Mapas Auto-Organizáveis para descobertas de perfis de comportamento e seu posterior uso para classificação/marcação (*labeling*) dos exemplos presentes no recorte de dados em estudo de forma automática. Nesta etapa, o recorte de dados utilizado foi idêntico ao da abordagem anterior (**4.b**), mas nada impede sua aplicação a porções diferentes dos dados de consumo.

Para o mapeamento dos comportamentos, os dados de consumo de cada dia da semana, no intervalo descrito, foram apresentados a uma rede SOM 3×3 e agrupados por similaridade utilizando a métrica da distância euclidiana. Os pesos sinápticos de cada um dos nós da rede que apresentou ativação foram tratados como modelos de comportamentos de consumo distintos. Desta forma, cada dia útil da semana teve seus comportamentos de consumo mapeados independentemente num conjunto de vetores sinápticos.

O uso desses modelos ocorre por meio da comparação por similaridade, novamente usando a distância euclidiana, de vetores de dados de teste com os vetores sinápticos computados na fase de treinamento. Desta forma, os exemplos de teste podem ser marcados com uma etiqueta que identifica o seu comportamento ou característica. Essa etapa visa dar suporte ao uso futuro de algoritmos de aprendizado supervisionado na análise dos dados de consumo.

3 Resultados e Discussão

Seguindo o que foi apresentado na seção 2, aqui serão discutidos os detalhes de desenvolvimento de cada uma das três abordagens mencionadas na etapa 4 da Figura 1, que são, a análise estatística, o uso de modelos de regressão e o uso dos SOM para descoberta de comportamentos, bem como os resultados obtidos por meio da aplicação desses procedimentos aos dados de consumo.

3.1 Análise Estatística

Nesta etapa, o objetivo era conhecer melhor a base de dados e começar a visualizar as principais características de consumo do laboratório avaliado, especialmente aquelas que permitissem iniciar a criação de um perfil para a entidade consumidora.

Para atingir esse objetivo, foi empregado um algoritmo de aprendizado não supervisionado, *k-means++*[3], capaz de encontrar grupos, baseado em áreas de densidade dos dados. O número de grupos (*clusters*) é um parâmetro k definido antes da aplicação do algoritmo.

Inicialmente, a aplicação do *k-means* forneceu a possibilidade de dividir os dados em três ou quatro faixas de consumo, conforme pode ser visualizado nas Figuras 2 e 3. Após a análise desses resultados, considerou-se a divisão em 4 faixas como mais adequada, já que apresenta uma divisão na qual os dados de cada faixa estão melhor agrupados e em consonância com a descrição dada para cada uma das faixas de consumo, a saber, baixo , médio, alto e muito alto.

Figura 2: Divisão dos dados em três faixas de consumo, baixo, médio e alto.

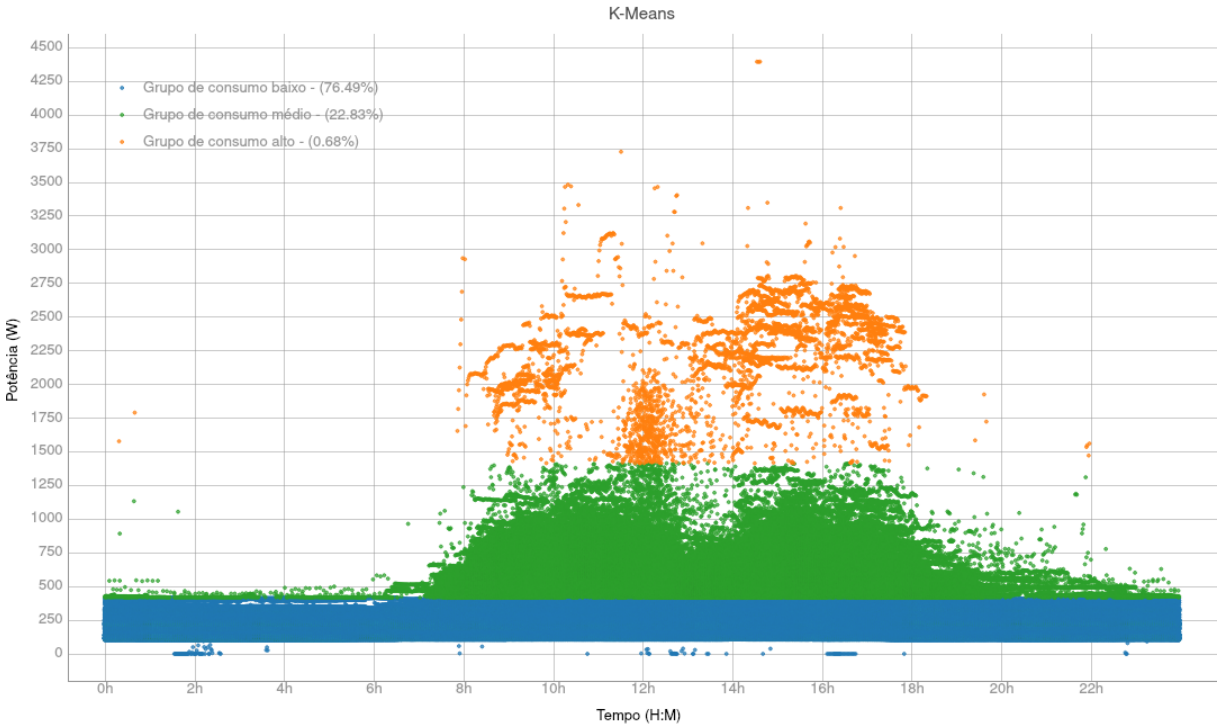

Fonte: próprio autor.

Figura 3: Divisão dos dados em quatro faixas de consumo, baixo, médio, alto e muito alto.

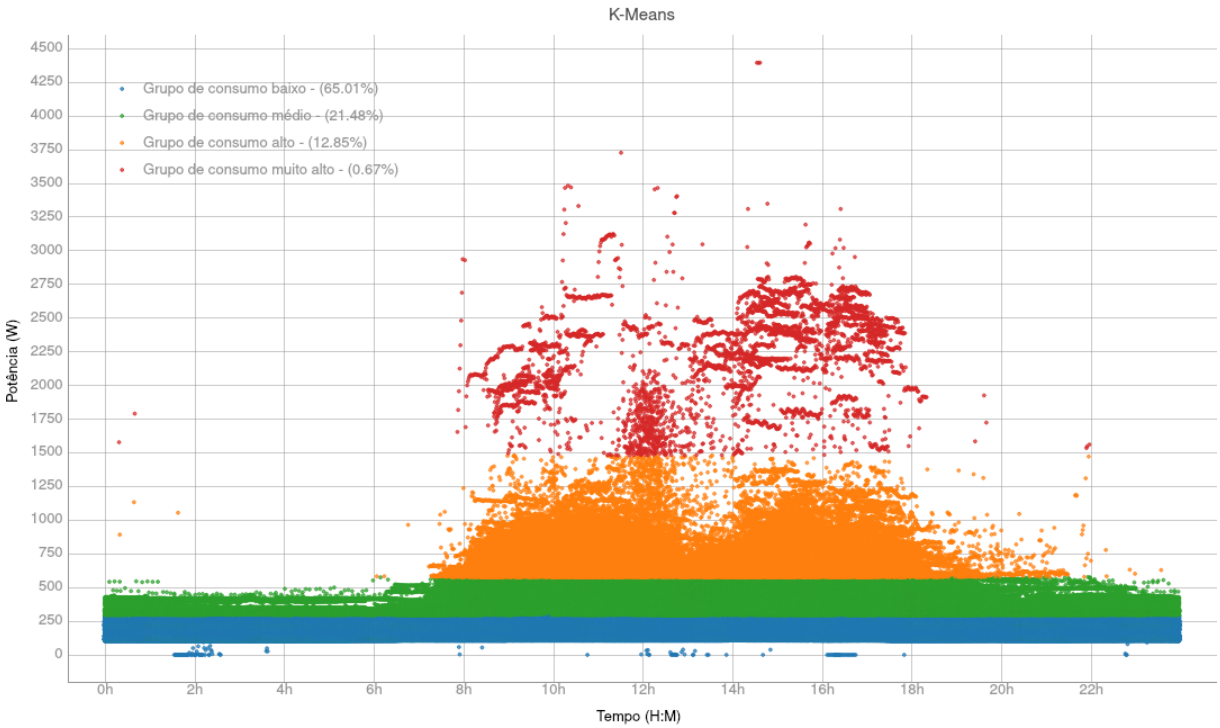

Fonte: próprio autor.

Tabela 1: Informações resultantes do *k-means* com três faixas de consumo, conforme a Figura 2.

Consumo	Baixo (azul)	Médio (verde)	Alto (laranja)
Centróide	201,78	633,26	2.195,64
Faixa (W)	-0,48 a 417,52	417,53 a 1.413,99	1.414.76 a 4.396,48
Quantidade de pontos	523.461 (76,49%)	156.234 (22,83%)	4.688 (0,68%)
Média	201,82	633,41	2.195,97
Desvio Padrão	80,48	164,82	378,01

Fonte: próprio autor.

Tabela 2: Informações resultantes do *k-means* com quatro faixas de consumo, conforme a Figura 3.

Consumo	Baixo (azul)	Médio (verde)	Alto (laranja)	Muito Alto (vermelho)
Centróide	175,98	415,00	741,99	2.218,20
Faixa (W)	-0,48 a 295,48	295,49 a 578,49	578,50 a 1.480,07	1.480,86 a 4.396,48
Quantidade de pontos	444.916	147.004	87.910	4.553
Porcentagem	65,01%	21,48%	12.85%	0,67%
Média	176,10	415,91	742,89	2.218,20
Desvio Padrão	55,90	84,08	142,97	360,48

Fonte: próprio autor.

Por meio da análise dos resultados apresentados nas Tabelas 1 e 2, percebeu-se que um total de 86,49% dos dados concentrava-se nas faixas de consumo baixo e médio, compreendendo consumos não superiores a 580W. Desta forma, os 13,52% restantes se dividem nas faixas alta e muito alta, nas proporções de 12,85% e 0.67% respectivamente e compreendendo consumos entre 580 e 4400W.

Em seguida, a contagem dos dados de consumo por mês, por dia da semana, por horário e uma combinação das visualizações por dia e por horário foi efetuada. Os histogramas resultantes podem ser visualizados para cada uma das faixa de consumo nas Figuras 4, 5, 6 e 7.

Figura 4: Ilustração dos histogramas do grupo de consumo baixo.

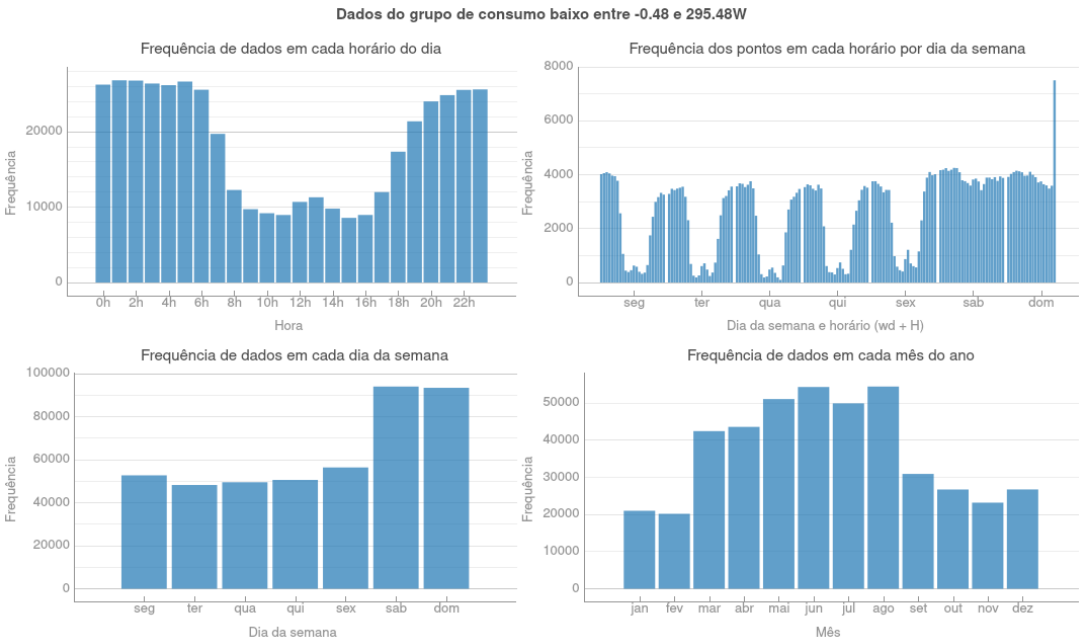

Fonte: próprio autor.

Figura 5: Ilustração dos histogramas do grupo de consumo médio.

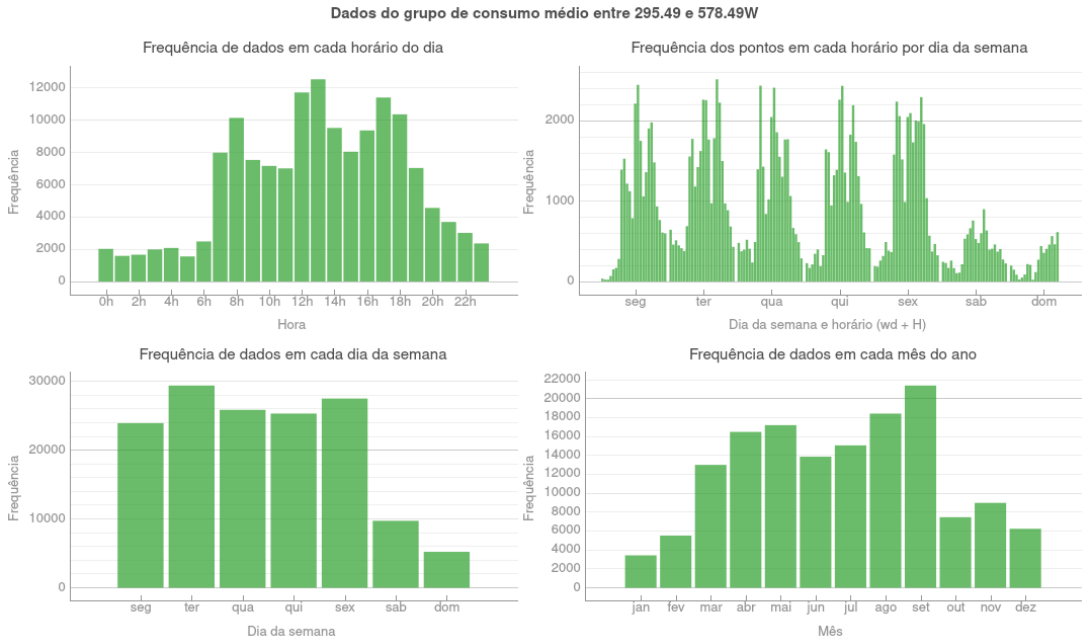

Fonte: próprio autor.

Figura 6: Ilustração dos histogramas do grupo de consumo alto.

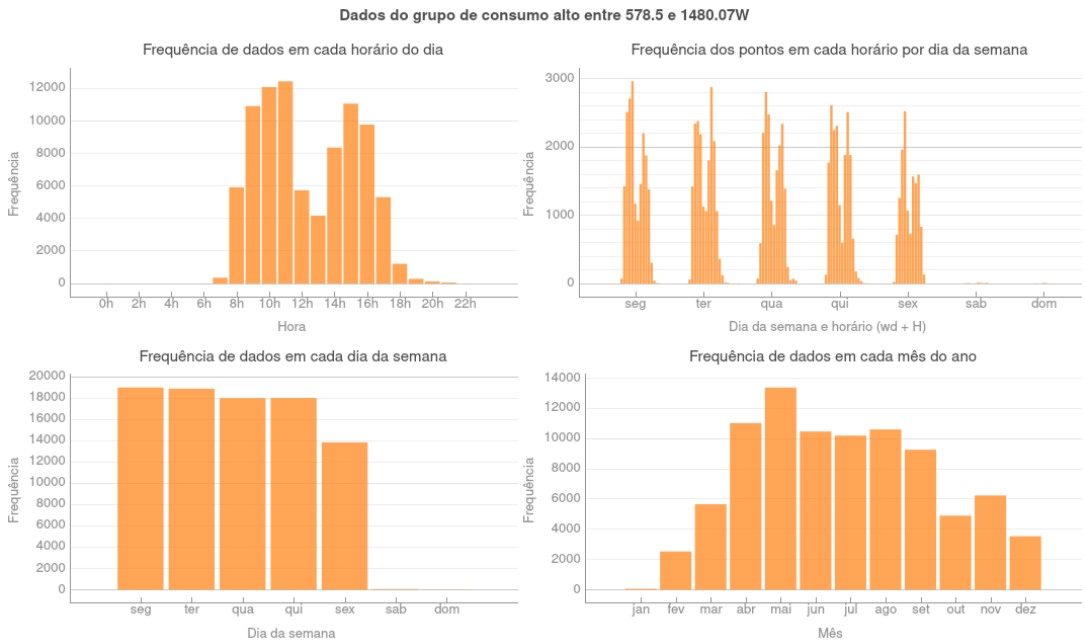

Fonte: próprio autor.

Figura 7: Ilustração dos histogramas do grupo de consumo muito alto.

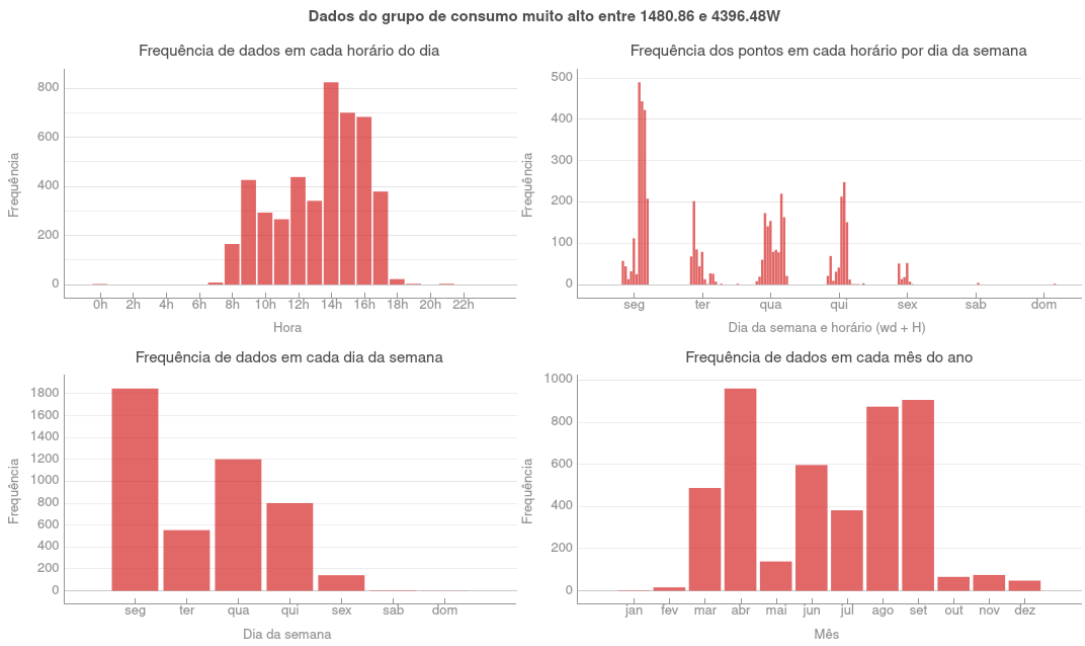

Fonte: próprio autor.

A análise desses histogramas, evidenciaram a diminuição da frequência de pontos nas faixas de consumo superiores, alto e muito alto, nos finais de semana, justificável pela diminuição do tráfego de pessoas no laboratório. Adicionalmente, no histograma referente a faixa de consumo muito alto, nota-se que os picos de consumo ocorrem nos meses de abril, agosto e setembro. Prosseguindo-se, a inspeção do consumo por horário demonstrou grande demanda no intervalo das 08:00 até às 17:00 horas. Por fim, observando-se especificamente o intervalo das 20:00 às 23:59, foi possível perceber que não existe grande contribuição de consumos das faixas alta e muito alta. Isso sugeriu, que a definição de limiares para classificação de consumos neste intervalo temporal como acima do esperado ou alarmes poderia não ser trivial, necessitando de uma abordagem mais sofisticada para sua definição.

3.2 Análise por Modelos de Regressão

Nesta abordagem, a solução encontrada foi usar o algoritmo de regressão linear para criar modelos para os dados de consumo no intervalo mencionado para cada dia da semana. A regressão linear [5], é um método estatístico baseado nos mínimos quadrados para modelagem de uma equação linear da relação entre uma variável dependente, e uma ou mais variáveis independentes, estabelecendo assim uma correlação entre os valores de origem (conjunto de treino) e as variáveis de destino (modelo previsto dos dados). Quando computada com apenas uma variável independente a regressão é denominada regressão linear simples. Para o caso de mais de uma variável independente ela é dita regressão linear múltipla, da qual a regressão polinomial pode ser considerada um caso especial. Em nossa aplicação, a regressão tomou a forma de um regressão polinomial, pois foram usadas como preditores potências da nossa variável independente, equação (1).

Os modelos de regressão foram computados variando-se o grau do modelo entre 1 e 5, os resultados desta exploração são apresentados na Figura 8, que ilustra o ajuste de vários modelos de regressão aos dados de consumo das quartas-feiras. Pôde-se perceber

que, apesar de ser possível adaptar o grau da regressão para cada um dos dias da semana, os modelos de grau 4 forneciam um bom compromisso entre o ajuste do modelo aos dados e a complexidade do modelo, e por esse motivo foram adotados como os modelos base a serem usados no cálculo dos limiares para classificação dos dados.

$$y = f(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5 ... + \beta_n x^n \tag{1}$$

Onde:

- y é a variável independente;
- β_n, $n = 1, 2, \ldots, n$ são os coeficientes do modelo;
- e $x, x^1, x^2, \ldots, x^n$ são potências da variável independente x

Figura 8: Ilustração do estudo da variação do grau dos modelos de regressão.

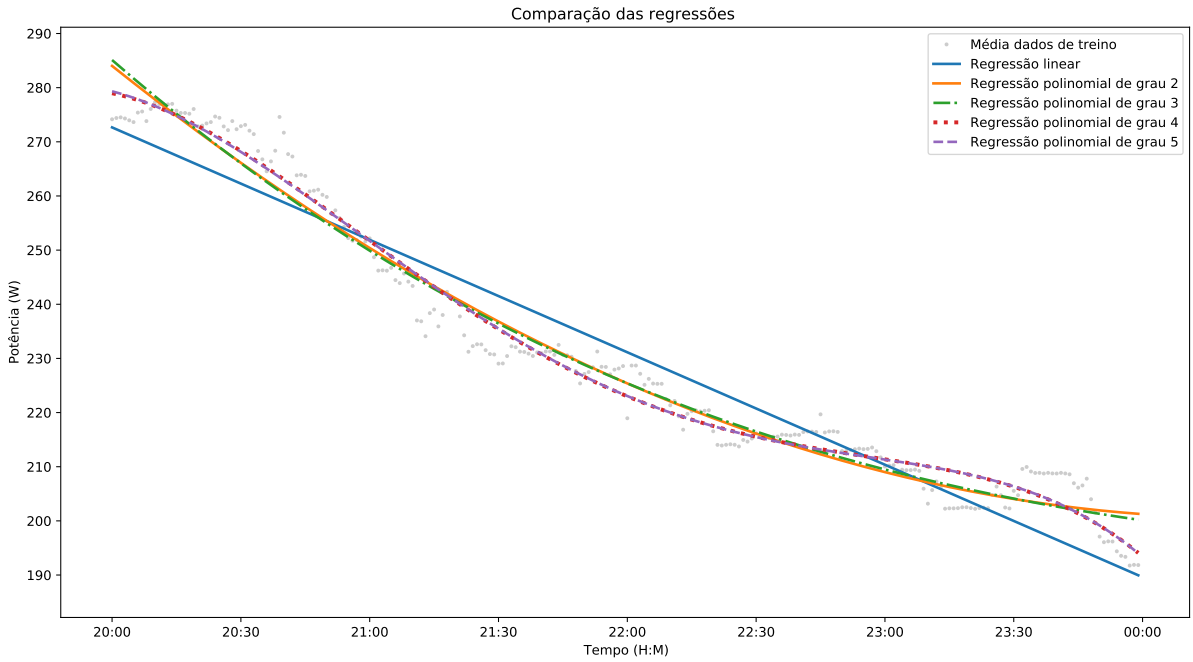

Fonte: próprio autor.

No que diz respeito a definição dos limiares, a Figura 9 fornece uma boa ilustração do processo. Nela pode-se observar a aplicação dos dados de treino para cálculo do modelo de regressão, seguido da estimação do erro e sua posterior adição aos valores produzidos pelo modelo de regressão produzindo os valores do limiar de classificação. Os limiares gerados por esse método apresentavam um característica ruidosa que poderia produzir resultados inesperados na classificação. Para suavizar a curva obtida foi utilizado o filtro Savitzky–Golay [6] com parâmetros de janela e grau do polinômio com valores 59 e 3 respectivamente.

Figura 9: Ilustração da metodologia para ajuste do modelo e criação do limiar, abordagem 1b.

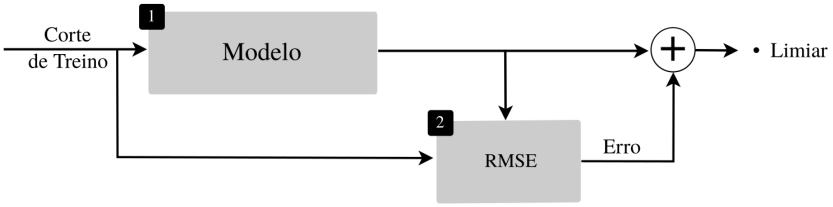

Fonte: próprio autor.

Para avaliar esta abordagem, exemplos de dados de consumo foram separados para realização de testes e classificados utilizando os modelos e limiares obtidos com os exemplos de treino. A classificação foi a seguinte em termos do consumo: baixo (dados abaixo da linha da regressão), esperado (dados entre a linha de regressão e o limiar), acima do esperado (dados acima do limiar até às 23:00) e alarme (são consumos classificados como acima do limiar após às 23:00). Adicionalmente, uma comparação das faixas produzidas pela classificação usando os modelos de regressão foi realizada com um agrupamento via *k-means* computado, com parâmetro $k = 4$, para todos os exemplos (treino e teste). Uma ilustração dos resultados dessa comparação, para os exemplos correspondentes às segundas-feiras, podem ser vistos nas Figuras 10 e 11.

Figura 10: Visualização da média dos exemplos, das faixas de consumo do *k-means*, $k = 4$, e dos limiares da regressão.

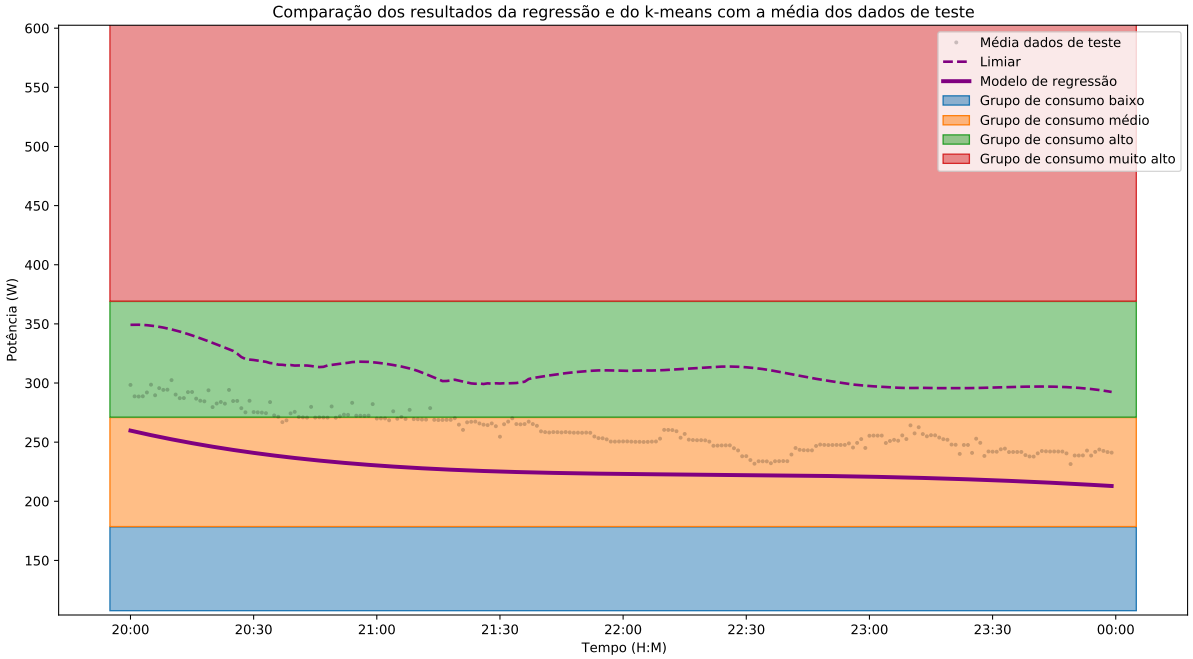

Fonte: próprio autor.

Figura 11: Visualização da classificação dos exemplos de acordo com os limiares da regressão.

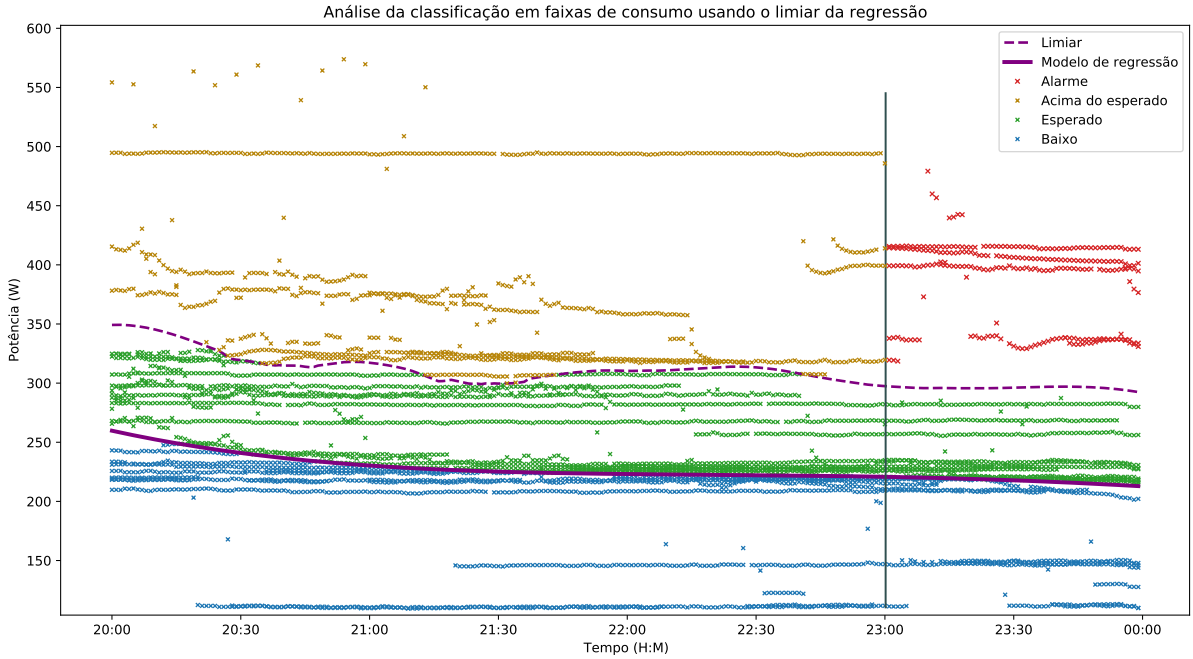

Fonte: próprio autor.

Na Figura 10, em relação ao resultado do *k-means*, observou-se que o limiar calculado localiza-se na região correspondente a faixa de consumo alto. Percebeu-se também, que a média dos valores dos exemplos apresenta-se acima da curva de regressão e abaixo da curva do limiar, exatamente na faixa denominada consumo esperado, demonstrando um bom ajuste dos limiares de classificação. A classificação, pelo modelo de regressão e limiar, de todos os exemplos do conjunto de teste em uma das quatro regiões definidas está ilustrada na Figura 11. Na Tabela 4, são apresentadas as porcentagens dos dados que foram classificados como acima do esperado e como alarme, assim como o total de pontos acima do limiar, para cada dia da semana. Esses valores foram obtidos fazendo o embaralhamento dos exemplos disponíveis e utilizando uma divisão de 60% dos exemplos para treino e 40% para teste. Foram realizadas 30 rodadas e as porcentagens são as médias desses resultados. Analisando-se os resultados percebeu-se que, em média, considerando-se todos os dias, 14,6% dos dados classificados como acima do esperado ou alarmes. Apenas como alarmes, a proporção é de 3.24% do total de dados de teste. Logo, 85,4% dos dados foram classificados nas classes de consumo esperado ou baixo. Observou-se também, que pela classificação do *k-means*, Tabela 3, em média, 23,84% dos dados, considerando todos os dias, são classificados nas faixas de consumo alto ou muito alto. Em nossa análise, a diferença de 9,24% entre a classificação pelo *k-means* e aquela feita pelo modelo de regressão é um indicativo da melhor seletividade da abordagem proposta. É importante destacar que, os dados originais não possuem nenhum tipo de qualificador ou etiqueta que sugira a qual classe ele pertença. Por isso, foi dada preferência ao uso de técnicas de aprendizado não supervisionado, já que estas não necessitam de etiquetas nos exemplos para sua aplicação. Por fim, na Tabela 5 e na Figura 12 são apresentados os valores médios dos limiares de classificação, juntamente com os valores dos limites de faixas da classificação via *k-means*, em *Watts*, para comparação. Pôde-se observar que, com exceção da sexta-feira, a média do limiar se encontra entre os limites das faixas de consumo

alto e muito alto, mesmo quando se adiciona o desvio padrão ao resultado. A questão particular das sextas feiras, se justifica pela observação dos histogramas da seção 3.1 os quais sugerem um perfil de consumo baixo para esse dia da semana, já que quase não existem ocorrências de valores de consumos nas faixas alto e muito alto. Novamente, esse resultado foi considerado um indicativo do funcionamento satisfatório dessa abordagem na separação dos dados em faixas de consumo.

Tabela 3: Porcentagens de classificação do total de dados nas faixas de consumo alta e muito alta via *k-means*.

	Segunda	Terça	Quarta	Quinta	Sexta	Média
Consumo Alto	26,35%	15,23%	13,90%	22,82%	21,75%	20,01%
Consumo Muito Alto	10,77%	4,59%	0,94%	2,76%	0,13%	3,83%
Porção total	37,12%	19,82%	14,84%	25,58%	21,88%	23,84%

Fonte: próprio autor.

Tabela 4: Porcentagens de classificação dos dados usando os modelos de regressão.

	Segunda	Terça	Quarta	Quinta	Sexta	Média
Porção de Alarmes	3,88%	2,99%	2,61%	2,95%	3,76%	3,23%
Porção Acima do Esperado	12,98%	12,04%	9,56%	11,92%	10,31%	11,36%
Total Acima do limiar	16,86%	15,03%	12,17%	14,87%	14,07%	14,60%

Fonte: próprio autor.

Tabela 5: Valores em *Watts* das médias dos limiares e dos limites de faixa da classificação via *k-means*.

	Segunda	Terça	Quarta	Quinta	Sexta	Média
Faixa de consumo Alto	271,43	279,95	281,13	282,23	268,26	276,60
Média do limiar	310,71	309,00	301,76	294,17	267,11	296,55
Desvio padrão	11,67	12,58	12,73	9,24	8,13	10,87
Faixa de consumo Muito Alto	369,47	405,13	483,09	451,03	374,31	416,60

Fonte: próprio autor.

Figura 12: Valores das médias dos limiares e os limites de faixa da classificação via *k-means* nos dias úteis da semana.

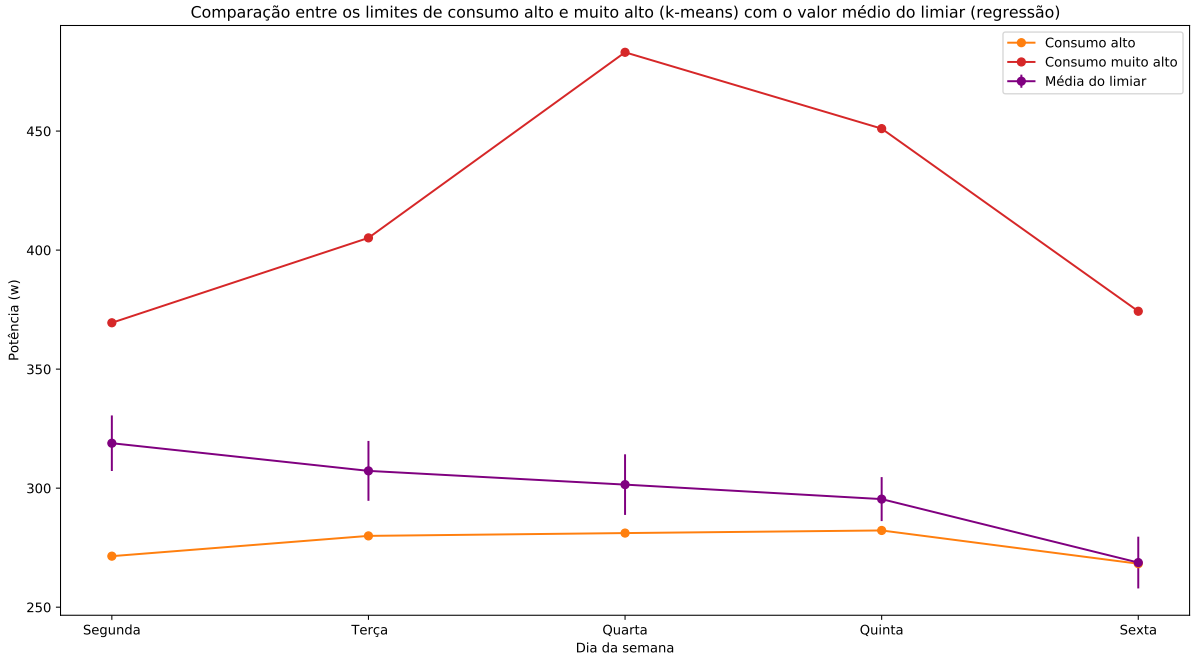

Fonte: próprio autor.

3.3 Descoberta de comportamentos via SOM

Nesta etapa, o objetivo era explorar os comportamentos distintos de consumo para cada dia da semana e depois usar o que foi aprendido para classificar estes exemplos automaticamente.

Para isso, foi usado o algoritmo de aprendizado não supervisionado SOM, ou Mapas Auto-Organizáveis. Trata-se de um algoritmo de aprendizado competitivo, cooperativo e adaptativo, um tipo de rede neural de aprendizado de quantização de vetores (LVQ) [7], para classificar exemplos em grupos com comportamentos distintos.

3.3.1 O Algoritmo SOM

A estrutura é construída sobre um mapa, uma abstração de um espaço vetorial, que é a base para gerar uma representação em baixa dimensão dos dados. Sobre o mapa são distribuídos *nós* – ou *neurônios* –, que armazenam vetores (pesos sinápticos da rede neural) de valores reais de mesmo comprimento que os exemplos do conjunto para qual o mapa será treinado e utilizado. O algoritmo pode ser resumido em cinco passos [8], como apresentado em 5:

1. **Inicialização:** Os pesos sinápticos $\mathbf{w}$ do mapa são inicializados aleatoriamente entre o menor e o maior valor do conjunto de dados. Com a restrição de que, os pesos de $\mathbf{w}_j(0)$ sejam diferentes para $j = 1, 2..., l$, onde l é o número de neurônios no mapa.
2. **Amostragem:** Um exemplo $\mathbf{x}$ do conjunto de treino é selecionado. A dimensão m do vetor de exemplo $\mathbf{x}$ é igual a dimensão do vetor sináptico.

3. **Seleção por similaridade:** O melhor casamento (*matching*) de um neurônio $i(\mathbf{x})$, no instante de tempo n, é encontrada a partir da distância euclidiana para a amostra:

$$i(\mathbf{x}) = arg\ min_j\ ||\mathbf{x}(n) - w_j||,\ j = 1, 2 \ldots l \tag{2}$$

4. **Atualização:** O ajuste do vetor sináptico é realizado em todos os neurônios respeitando a função de vizinhança. Onde o principal aprendizado é concentrado no neurônio vencedor.

$$w_j(n+1) = w_j(n) + \eta(n)\ h_{j,i(\mathbf{x})}\ (n)\ (\mathbf{x}(n) - w_j(n)) \tag{3}$$

para $\eta(n)$ como o parâmetro de aprendizagem e $h_{j,i(\mathbf{x})}$ como função de vizinhança, concentrada sobre o neurônio vencedor $i(\mathbf{x})$; a função de vizinhança e aprendizado decrescem conforme o número de iterações do algoritmo.

5. **Continuação:** O algoritmo é repetido a partir do passo dois, até que não sejam mais observadas modificações significativas no mapa ou até um número pré-definido de iterações.

Na Figura 13, é ilustrado o algoritmo. Para um exemplo qualquer, selecionado na Etapa 2, o neurônio mais semelhante é o cinco, que foi selecionado na Etapa 3. Na Etapa 4, o neurônio e seus vizinhos são atualizados. A última etapa constitui a repetição do algoritmo a partir da Etapa 2.

Figura 13: Ilustração do funcionamento do algoritmo dos Mapas Auto-Organizáveis.

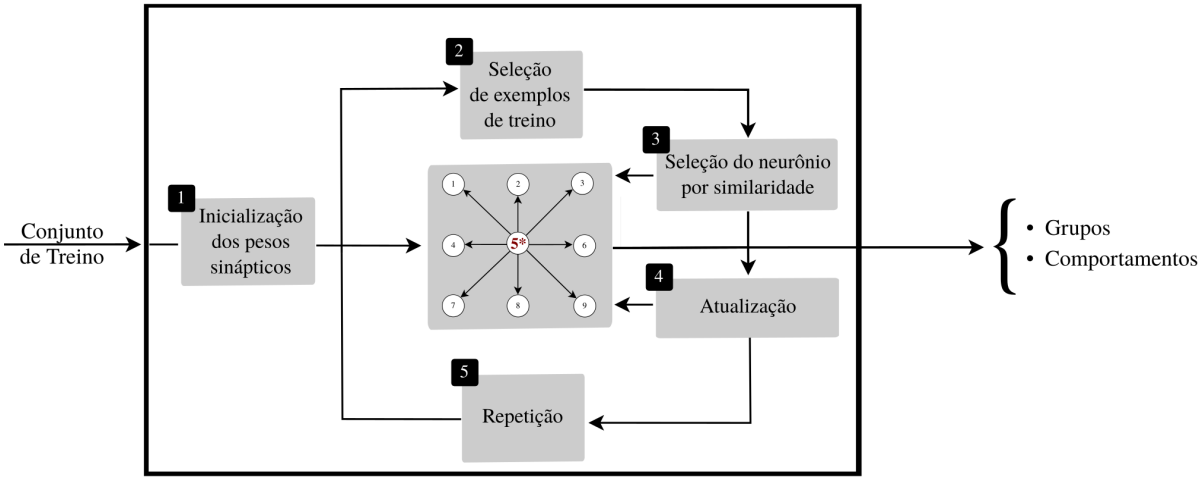

Fonte: próprio autor.

3.3.2 Aplicação dos Mapas Auto-Organizáveis

A aplicação do algoritmo se iniciou com o treinamento de um modelo da rede neural, que retornou um mapa com padrões correspondentes aos comportamentos mais recorrentes encontrados nos dados. O SOM foi treinado para os dados dos períodos de 2018.1 e 2018.2 do ano letivo da UFCG, especificamente no intervalo de horários já definido no estudo de estatísticas, entre às 20:00 e às 23:59.

Realizado o treinamento, os vetores sinápticos dos comportamentos encontrados foram utilizados para classificar/marcar os exemplos de teste com base na similaridade de

cada um deles com os vetores, em seguida os exemplos foram divididos em seus grupos correspondentes, esse agrupamento está ilustrado na Figura 14, onde em roxo estão representados os pesos sinápticos, e nas demais cores os exemplos agrupados. Estes grupos correspondem aos comportamentos mapeados para as segundas-feiras, mas o procedimento foi realizados para todos os dias úteis da semana. Após observar os resultados do agrupamento por comportamentos, foram extraídas algumas informações sobre a distribuição dos exemplos de teste nos grupos mapeados, Tabela 6. Foi possível perceber que os grupos dividem os exemplos de acordo com as diferenças no modo como a demanda por eletricidade transcorreu. A divisão dos exemplos em grupos também permitiu ajustar modelos de regressão mais específicos, provavelmente permitindo uma melhor classificação. Acredita-se ainda, que esse resultado permitirá uma maior resolução na criação de um perfil de consumo por meio da correlação entre informações dos exemplos de cada grupo com os dados da análise estatística.

Figura 14: Ilustrações dos comportamentos no mapa. Em roxo está os pesos sinápticos, em pontos coloridos os exemplos agrupados.

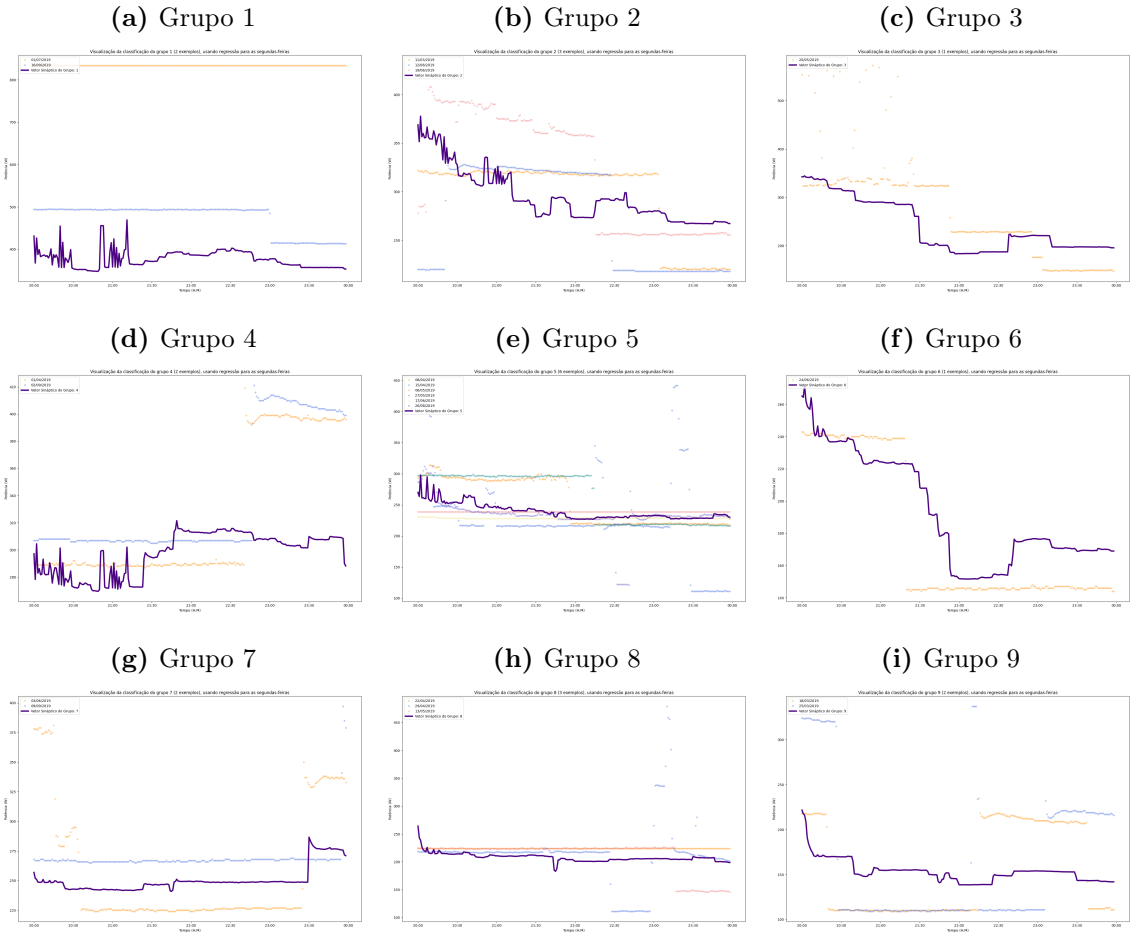

Fonte: próprio autor.

Tabela 6: Resultados para os grupos de comportamento, ilustrados nas Figuras 14.

	Número de Exemplos	Percentual de Exemplos Mapeados
Grupo 1	2	9.1%
Grupo 2	3	13.6%
Grupo 3	1	4.5%
Grupo 4	2	9.1%
Grupo 5	6	27.3%
Grupo 6	1	4.5%
Grupo 7	2	9.1%
Grupo 8	3	13.6%
Grupo 9	2	9.1%

Fonte: próprio autor.

3.4 Classificação dos exemplos dos grupos de comportamentos via regressão

De posse dos grupo de exemplos separados por comportamentos, os algoritmos de regressão foram aplicados para classificar dados. Os resultados da classificação estão presentes nas Figuras 15, 16 e 17. Nelas, a linha sólida em azul escuro representa o modelo de regressão, a linha azul claro corresponde ao limiar, em roxo está ilustrado o vetor de pesos sinápticos e os demais pontos coloridos são os exemplos que fazem parte do grupo. Os exemplos têm os pontos coloridos segundo sua classificação pelo modelo de regressão nas faixas de consumo, baixo, em azul, esperado, em verde, acima do esperado, em amarelo, e alarmes, em vermelho.

Figura 15: Ilustração da classificação do 2º grupo da quarta-feira usando regressão.

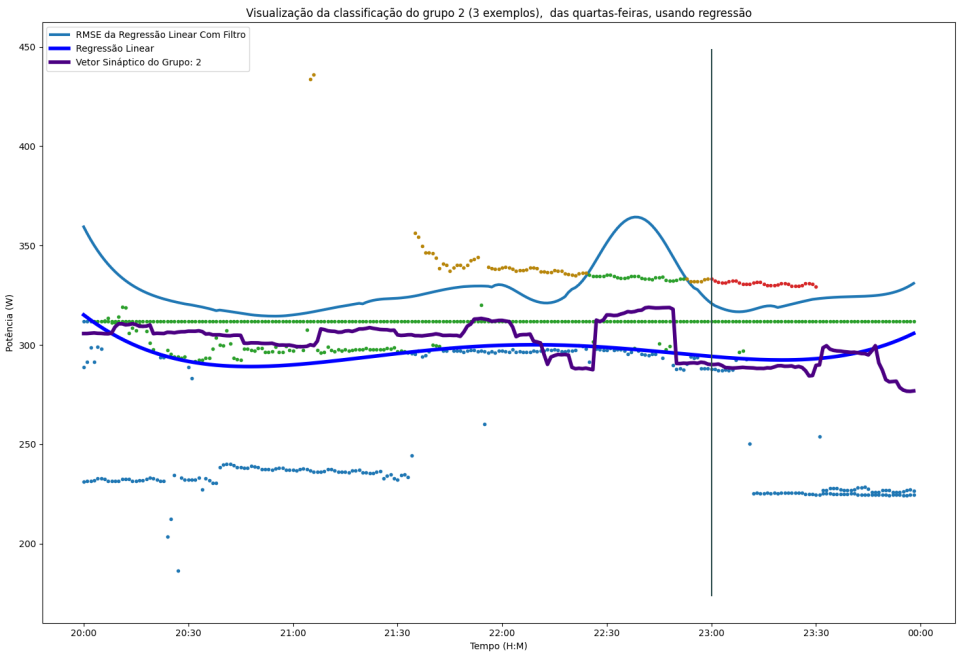

Fonte: próprio autor.

Figura 16: Ilustração da classificação do 3º grupo da sexta-feira usando regressão.

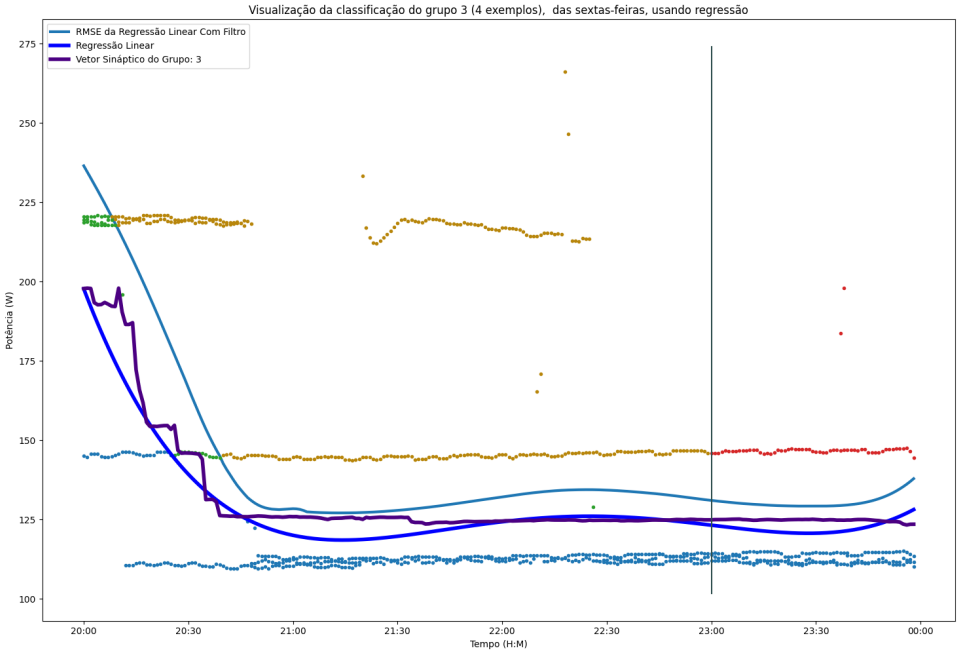

Fonte: próprio autor.

Figura 17: Ilustração da classificação do dia 15/04/2019, pertencente ao 5º grupo da segunda, usando regressão.

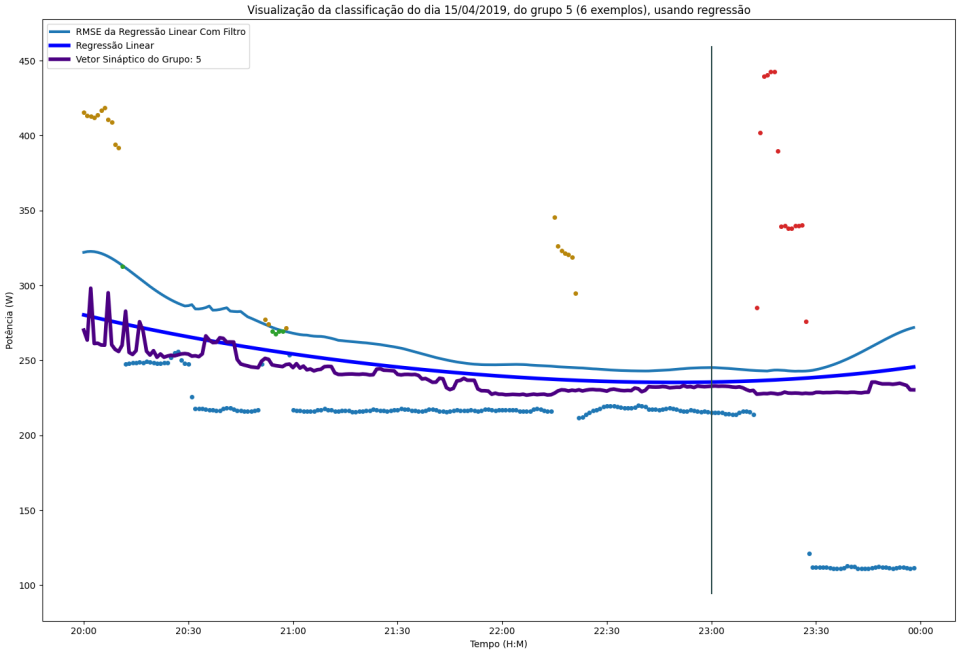

Fonte: próprio autor.

Na Figura 15 observa-se o resultado da classificação dos dados dos exemplos de teste do 2º grupo da quarta-feira, e na Figura 16 o da classificação do 3º grupo da sexta-feira, ambos usando modelos de regressão ajustados usando dados de treino agrupados nos grupos em questão. Das figuras, observou-se que o modelo de regressão captura bem o comportamento mapeado pelo SOM em ambos os casos, com a vantagem de ser mais

suave e portanto mais facilmente aplicável para classificação. Pôde-se ainda, apreciar o papel do SOM na determinação dos comportamentos distintos para os dias úteis da semana, pois, permitiu a aplicação da regressão para criação de modelos mais específicos. Sem os resultados do SOM não seria possível determinar quantos modelos de regressão e em que porção dos dados eles deveriam ser treinados. Adicionalmente, na Figura 17, uma ilustração mais próxima de um caso de uso do sistema é apresentada. Nela se vê os dados de uma segunda-feira específica, que foi mapeada no grupo de comportamento 6. A ilustração representa o que seria visto ao final do intervalo das 20:00 às 23:59 deste dia. Ao início do intervalo, os dados seriam classificados utilizando um modelo de regressão geral, ou seja, ajustado sobre todas as segundas-feiras sem distinção. Com o passar do tempo e com a chegada de mais pontos se tornaria possível mapear os dados em um dos grupos de comportamento específico para as segundas-feiras, no caso o grupo 6, resultando na ilustração mencionada.

4 Conclusão

Ao iniciar a pesquisa, o objetivo era criar um perfil de consumo para a unidade consumidora analisada, o LAPS-UFCG, bem como ser capaz de identificar consumos fora do padrão no intervalo das 20:00 às 23:59, classificando-os como acima do esperado e alarmes.

No que diz respeito a criação de um perfil de consumo considera-se que este objetivo foi atingido, uma vez que a análise estatística dos dados fornece uma detalhada visão do consumo de eletricidade do LAPS-UFCG.

Já para a questão da identificação de consumos fora do padrão, conforme discutido na seção 3, acredita-se que o uso dos modelos de regressão forneceram uma alternativa adequada para separação em faixas de consumo, bem como para a detecção dos dados de consumo que estão acima do esperado, ou que constituem alarme.

Com os resultados produzidos pelo uso do SOM, um mapeamento de comportamentos específicos para cada dia útil da semana foi possível, aumentando o nível de detalhes com o qual se pode estudar o consumo. Consequentemente, um refinamento dos modelos de regressão, ao criar um modelo para cada comportamento, também foi obtido, o que afeta a qualidade da classificação, porém o estudo desse efeito ainda precisa ser mensurado.

De forma geral, as bases para a criação de um sistema de monitoramento e gerenciamento de energia estão lançadas e o desenvolvimento do sistema já se encontra em andamento.

Como trabalhos futuros, a análise das potências reativas e fatores de potência das fases do sistema elétrico precisam ser realizadas e a possibilidade de aplicação de algoritmos de aprendizado supervisionado, precisa ser explorada.

Referências

[1] International Energy Agency. World energy outlook 2019. IEA (2019), 2019.

[2] Da Editora de Economia. Desperdício de energia gera perdas de r$ 12,6 bilhões. ABESCO - Associação Brasileira das Empresas de Serviços de Conservação de Energia, 2015.

[3] David Arthur and Sergei Vassilvitskii. k-means++: The advantages of careful seeding. Technical report, Stanford, 2006.

[4] Teuvo Kohonen. The self-organizing map. *Proceedings of the IEEE*, 78(9):1464–1480, 1990.

[5] Douglas C Montgomery, Elizabeth A Peck, and G Geoffrey Vining. *Introduction to linear regression analysis*, volume 821. John Wiley & Sons, 2012.

[6] William H Press and Saul A Teukolsky. Savitzky-golay smoothing filters. *Computers in Physics*, 4(6):669–672, 1990.

[7] Teuvo Kohonen. Learning vector quantization. In *Self-organizing maps*, pages 175–189. Springer, 1995.

[8] Simon Haykin. *Redes neurais: princípios e prática.* Bookman Editora, 2007.