UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE ENSINO SUPERIOR DO SERIDÓ
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

FEATURES ANALYZER: DESENVOLVIMENTO DE UMA PLATAFORMA DE ANÁLISE E VISUALIZAÇÃO DE DADOS

ZAÚ JÚLIO ARAÚJO GALVÃO

Caicó- RN
2022

ZAÚ JÚLIO ARAÚJO GALVÃO

FEATURES ANALYZER: DESENVOLVIMENTO DE UMA PLATAFORMA DE ANÁLISE E VISUALIZAÇÃO DE DADOS

Trabalho de conclusão de curso apresentado ao curso de graduação em Sistemas de Informação, como parte dos requisitos para obtenção do título de Bacharel em Sistemas de Informação da Universidade Federal do Rio Grande do Norte.

Orientador(a): Ms. Luiz Paulo de Assis Barbosa.
.

Caicó- RN
2022

LISTA DE QUADROS

Quadro 1 – Cronograma de Atividades 16

LISTA DE SIGLAS

ES Engenharia de Software

GUI Graphical User Interface

CSS Cascading Style Sheets

SUMÁRIO

1 INTRODUÇÃO **6**
1.1 Contextualização e Problema **6**
1.2 Objetivos **6**
1.2.1 Objetivo Geral 6
1.2.2 Objetivos Específicos 6
1.3 Delimitação do Estudo **7**
1.4 Justificativa **7**
1.5 Apresentação do Trabalho **8**

2 FUNDAMENTAÇÃO TEÓRICA **9**
2.1 Análise e visualização de dados **9**
2.2 Aprendizado de Máquina **9**
2.3 Engenharia de Software **11**
2.4 Linguagens de Programação **11**
2.5 Bibliotecas **12**
2.5.1 Numpy 12
2.5.2 Pandas 12
2.5.3 Scikit-learn 13
2.5.4 PyQt 13
2.5.5 Seaborn/Matplotlib 13
2.6 Trabalhos Relacionados **13**

3 METODOLOGIA **14**
3.1 Questões de Pesquisa **14**
3.2 Proposta Metodológica **14**
3.3 Atividades **15**
3.3.1 Cronograma de Atividades 15

4 DESENVOLVIMENTO DA PESQUISA **17**
4.1 Levantamento de Requisitos **17**
4.1.1 Requisitos Funcionais 17
4.1.2 Requisitos Não Funcionais 18
4.2 Proposta de Solução **19**
4.2.1 Interfaces de Código 19
4.2.2 Interface Gráfica 19

4.2.2.1 Widgets 20
4.2.2.2 Estilização 20
4.2.2.3 Gráficos 21
4.2.3 Gerenciamento de Dados 21

5 RESULTADOS 23

6 CONCLUSÃO 24
6.1 Discussão 24
6.2 Contribuições 24
6.3 Limitações 25
6.4 Trabalhos Futuros 25

REFERÊNCIAS 26

APÊNDICE A CRONOGRAMA DE ATIVIDADES 27

Capítulo 1
Introdução

[PENDENTE]

1.1 Contextualização e Problema

A análise de dados é um dos principais fatores para o sucesso de uma empresa, pois é através dela que é possível obter informações que se tornam valiosas para a tomada de decisões. Logo, dado o aumento da quantidade de dados gerados e a necessidade de se obter informações a partir deles, gerou-se o interesse por ferramentas que auxiliem na análise e visualização de dados.

Um grande conjunto de ferramentas já está disponível online, porém, a maioria delas não é gratuita, performática e nem de código aberto. A ausência de ferramentas deste tipo é um fator notável, visto que nem sempre as empresas possuem recursos ou pessoal para desenvolver ferramentas deste tipo.

Nesta perspectiva, surge a oportunidade de se desenvolver uma ferramenta que atenda aos critérios citados anteriormente, e que seja facilmente extensível para novas funcionalidades e diferentes tipos e fontes de dados.

1.2 Objetivos

1.2.1 Objetivo Geral

O objetivo deste trabalho é o estudo e desenvolvimento de um projeto de software com a finalidade de análise e visualização de dados, que seja modular e facilmente extensível, para atender a vários propositos e fontes de dados.

1.2.2 Objetivos Específicos

- Identificar diferentes problemas de análise de dados, tipos e fontes de dados.
- Modelar um projeto de software que atenda as necessidades identificadas, utilizando os conceitos de Engenharia de Software (ES).
- Implementar o software modelado.

- Testar e validar o software para com aplicação em laboratório.
- Documentar o software para futuras modificações.

1.3 Delimitação do Estudo

As ferramentas de visualização e análise de dados possuem um papel fundamental na tomada de decisão, sendo assim sua utilização é cada vez mais comum em diversas áreas. No entanto, a maioria das ferramentas disponíveis no mercado são proprietárias, de código fechado ou foram criadas em linguagens pouco utilizadas, o que diminui sua acessibilidade e dificulta o uso. Além disso, a maioria das ferramentas disponíveis são específicas para um tipo de problema, o que dificulta a sua utilização em diversos contextos.

Diante disso, o presente trabalho tem como objetivo a extensão de uma ferramente de visualização e análise de dados desenvolvida durante o projeto de pesquisa SmartEnergy. O projeto SmartEnergy tinha como objetivo a análise de dados de consumo energético em séries temporais. Logo, esse trabalho busca realizar o estudo da capacidade de extensão da ferramenta para outros contextos e evolução dela para uma arquitetura modular e de uso mais amplo.

A ferramenta foi desenvolvida em Python, utilizando a biblioteca Matplotlib para a visualização dos dados. A biblioteca Matplotlib é uma biblioteca de visualização de dados 2D em Python, que produz gráficos de qualidade de publicação em uma variedade de formatos impressos e ambientes interativos em plataformas diversas. A interface gráfica do usuário Graphical User Interface (GUI) foi desenvolvida utilizando a biblioteca PyQt que fornece um conjunto de interfaces para a biblioteca Qt. A biblioteca Qt é uma biblioteca de código aberto para desenvolvimento de aplicações multiplataforma.

1.4 Justificativa

A tarefa de análise de dados é complexa e exige o conhecimento e emprego de diversas técnicas de processamento. Cada problema requer uma abordagem diferente, e a escolha da técnica mais adequada é um desafio, necessitando de uma vasta gama de ferramentas e conhecimentos.

O processo exploratório da análise de dados requer o emprego de técnicas de visualização de dados, que permitem a compreensão dos dados e a identificação de padrões e tendências. Logo após a visualização dos dados é identificado o problema a ser resolvido, e então a escolha das técnicas que seram utilizadas para a resolução do problema. Frequentemente, a escolha das técnicas é baseada em experiência e intuição, necessitando de uma série de testes e ajustes dos parâmetros para a obtenção de resultados satisfatórios.

Além disso, a aplicação de determinadas técnica são realizadas em conjunto, e a escolha da ordem de aplicação das técnicas é um desafio, pois a ordem de aplicação das técnicas pode influenciar no resultado final. Por exemplo, a aplicação de técnicas de redução de dimensionalidade antes da aplicação de técnicas de agrupamento pode resultar em um agrupamento mais eficiente. Logo, existe um número grande de possibilidades de combinação de técnicas, e a escolha da melhor combinação é um desafio.

Desta forma, a proposta deste trabalha é a criação de uma plataforma para análise e visualização de dados, que permita a escolha das técnicas, a combinação e a visualização dos resultados. A plataforma será desenvolvida através do levantamento de requisitos necessários e o desenvolvimento de um protótipo que atenda aos mesmos.

1.5 Apresentação do Trabalho

No capítulo seguinte, fundamentação teórica, é discorrido assuntos relacionados ao trabalho, como Análise e visualização de dados, Aprendizado de Máquina, Engenharia de Software e as linguagens e bibliotecas utilizadas no desenvolvimento do sistema proposto.

No terceiro capítulo é apresentado os tópicos relacionados a modelagem do sistema, contendo os requisitos, funcionais e não funcionais, diagramas, modelo de dados e a arquitetura modular do sistema.

O quarto capítulo é dedicado a implementação do sistema, contendo a descrição do processo de desenvolvimento, a arquitetura do sistema, a descrição das tecnologias utilizadas e a descrição do processo de desenvolvimento.

Após o desenvolvimento do sistema, no quinto capítulo é apresentado os resultados obtidos com o sistema, contendo a descrição da interface, exemplos de uso e a avaliação do sistema.

Por fim, é apresentado a conclusão obtida com o presente trabalho, bem como sugestões de trabalhos futuros. Seguido das referências bibliográficas utilizadas durante este trabalho, um apêndice com materias relacionados ao trabalho e um anexo com o código fonte do sistema.

Capítulo 2
Fundamentação Teórica

2.1 Análise e visualização de dados

A Análise de dados é uma tarefa complexa, mas de fundamental importância para a tomada de decisões. Ela pode ser descrita como um processo de transformação de dados em informações que tenham valor. Com a crescente produção e coleta de dados, pelo surgimento do IOT e dos próprios usuários, esta tarefa tornou-se de suma importância para a evolução da Web como a conhecemos.

O processo de análise de dados pode ser divida em três etapas:

- **Pré-processamento**: como formatação, remoção de dados faltantes e valores atípicos (*Outliers*), normalização, etc. Por exeplo a remoção de *Outliers*, problemas durante a coleta ou arma
- **Processamento**: pode ser realizada de diversas formas, como por exemplo a aplicação de métodos estatísticos ou algoritmos de aprendizado de máquina. Por exemplo: regressão, classificação, agrupamento, predição, otimização, entre outros.
- **Pós-processamento**: consiste na apresentação dos resultados obtidos, que pode ser através de simples tabelas, gráficos, modelos matemáticos ou até valores numéricos. Por exemplo: visualização de dados em gráficos de séries históricas.

Por fim, a visualização de dados é uma tarefa crucial para a realização de todo o processo, pois é através dela que o usuário realiza a avaliação do processamento para averiguar o emprego dos métodos selecionados e a qualidade dos resultados obtidos.

2.2 Aprendizado de Máquina

O aprendizado de máquina consiste em conjunto de algoritmos com o objetivo de resolver um problema de forma que algoritmos classicos não conseguem ou não operam de forma eficiente. Eles são capazer de gerar modelos matemáticos com base em dados, que podem ser utilizados para prver o comportamento dos dados, agrupar os dados ou classificá-los.

Os problemas que estes algoritmos resolvem podem ser divididos em algumas categorias, como por exemplo: regressão, classificação, agrupamento, predição, detecção de anomalias, rankeamento, recomendação, otimização, entre outros.

- **Regressão**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.
- **Classificação**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.
- **Agrupamento**: consiste em encontrar grupos de dados que possuem características semelhantes. Esses grupos podem ser utilizados para realizar análises mais detalhadas sobre os dados.
- **Predição**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.
- **Detecção** de anomalias: consiste em encontrar dados que possuem características diferentes dos demais. Esses dados podem ser utilizados para realizar análises mais detalhadas sobre os dados.
- **Rankeamento**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.
- **Recomendação**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.
- **Otimização**: consiste em encontrar uma função que descreve a relação entre uma variável dependente e uma ou mais variáveis independentes. A função encontrada pode ser utilizada para prever o valor da variável dependente para novos valores da variável independente.

Cada algoritmo citado, e muitos outros, já estão implementados em bibliotecas de código, algumas de código aberto, como por exemplo o scikit-learn, e outras de código fechado, como por exemplo o MATLAB. Estas bibliotecas são utilizadas para estudo e criação de plataformas para a realização de análises de dados.

2.3 Engenharia de Software

O desenvolvimento de um software é complexo e envolve várias etapas, como o levantamento de requisitos, modelagem do software, desenvolvimento, testes, validão, implementação entre outras. Essas etapas buscam garantir a produção e qualidade do software conforme as necessidades levantadas previamente e validadas.

A engenharia de software surgiu com o objetivo de facilitar e padronizar os projetos e o desenvolvimento de software, para que aumentar eficiência e qualidade do software produzido. Para isso, a engenharia de software utiliza diversas técnicas e ferramentas, como por exemplo: Design Patterns, Testes, entre outras.

Desenvolvendo algumas dessas técnicas: os Design Patterns, são soluções comuns para vários problemas de projeto, de forma com que possam ser utilizados em contextos diversos.E os Testes, que tem por objetivo garantir a qualidade do software, através da verificação de suas funcionalidades.

2.4 Linguagens de Programação

A linguagem escolhida para esse projeto foi o Python, presente entre as linguagens mais utilizadas no mundo, com uma vasta comunidade e um número crescente de bibliotecas. A linguagem Python é de alto nível, multiparadigma, possui tipagem dinâmica e forte. Além disso, utiliza de uma sintaxe simples e fácil de aprender para pessoas que já possuem conhecimento em outras linguagens de programação, assim como para iniciantes.

A linguagem executa sobre uma máquina virtual, chamada de Python Virtual Machine (PVM), que é responsável por interpretar o código fonte e executar as instruções. A PVM é uma máquina virtual baseada em pilha. Em um software python o código é compilado para bytecodes, uma linguagem intermediária, que a seguir são transpilados pela PVM código de máquina. O Python usa a compilação just-in-time (JIT), que compila o código fonte para bytecodes e depois para código de máquina, em tempo de execução.

O CPython é a implementação mais popular da linguagem Python, que é a implementação oficial da linguagem, e é a implementação que será utilizada nesse projeto. Desenvolvido em C, o CPython é multiplataforma, ou seja, pode ser executado em qualquer sistema operacional e arquitetura. O CPython funciona na seguinte maneira a seguir:

1. O código fonte é compilado para bytecodes.
2. O bytecodes é interpretado pela PVM.
3. A PVM executa o código.

4. O código é compilado para código de máquina.
5. O código de máquina é executado.

O Python utiliza um sistema de gerenciamento de memória automático, que é responsável por gerenciar a alocação e desalocação de memória. O Python possui um coletor de lixo, que é responsável por liberar a memória que não está sendo utilizada. A linguagem trata bem questões relacionadas a paralelismo, concorrência e processamento assíncrono, através de bibliotecas como o asyncio, que é uma biblioteca de código aberto, que implementa o modelo de programação assíncrona.

Em relação a performance a linguagem é relativamente lenta, quando comparado a opções como C e C++, mas possui uma comunidade ativa, com uma vasta gama de bibliotecas e frameworks, esse é o principal *trade-off* da linguagem. Logo assim, devido a sua fama, comunidade, rica biblioteca e a alta curva de aprendizado, o Python foi escolhido para o desenvolvimento desse projeto.

2.5 Bibliotecas

Bibliotecas são conjuntos de códigos que podem ser importados para outros projetos, realizando tarefas específicas com resolução já implementadas. A seguir serão apresentadas as principais bibliotecas utilizadas nesse projeto:

2.5.1 Numpy

O Numpy é um biblioteca fundamental para a computação científica. Ela possui implementações de vetores n-dimensionais em C, que são compilados executadas de maneira nativa, resultando em alta perfomance. Além disso, o Numpy já dispôe de uma vasta gama de funções matemáticas e operações de álgebra linear. Usando o Numpy é possível realizar por exemplo a normalização de um conjunto de dados com apenas uma linha de código.

2.5.2 Pandas

O Pandas, que por sua vez faz uso do Numpy, é uma biblioteca de open-source, que estruturam os dados em tabels (Dataframes), estruturas multidimensionais de dados, utilizados para análise de dados. Por utilizar o Numpy, além de uma vasta game de funções matemáticas, o Pandas também possui performance de alto nível. Com o Pandas é possível realizar várias operações com os dados, como ordenação, filtragem, entre outros.

2.5.3 Scikit-learn

O Scikit-learn, como o próprio nome sugere, é uma biblioteca de machine learning, que possui implementações de algoritmos de aprendizado de máquina, estatísticos e de mineração de dados. O Scikit-learn possui conjunto considerável de algoritmos de classificação, regressão, agrupamento, redução de dimensionalidade, entre outros. Além disso, ele possui uma grupo de métricas de avaliação, que são utilizadas para avaliar o desempenho dos modelos criados. Utilizando a biblioteca é possível realizar por exemplo a criação de um modelo de árvore de decisão, um exemplo de algoritmo de aprendizado supervisionado, que é utilizado para classificação e regressão.

2.5.4 PyQt

O PyQt é a biblioteca responsável por criar as interfaces gráficas de usuário (GUI) do projeto. Sobe licença GPL, o PyQt é uma biblioteca de código aberto, que opera através de wrappers, funções que encapsulam as bibliotecas pré-compiladas do Qt. O Qt por sua vez, é uma biblioteca, também de código aberto, que dispões de uma série de widgets, layouts, entre outros componentes que podem ser facilmente utilizados para a criação de interfaces gráficas. Outra vantagem do PyQt é sua compatibilidade com vários sistemas operacionais, como Linux, Windows, Mac OS, entre outros.

2.5.5 Seaborn/Matplotlib

O Seaborn é a bilbioteca gráfica escolhida nesse projeto para tratar a visualização dos dados. Ela é utiliza o Matplotlib como base, fornecendo várias interfaces de alto nível para a criação e personalização de gráficos. O Seaborn possui um conjunto de possibilidades como por exemplo a criação de gráficos de dispersão, gráficos de linha, gráficos de barras, entre outros. Utilizando ela é possível embutir os gráficos gerados a interface gráfica criada com o PyQt.

2.6 Trabalhos Relacionados

[PENDENTE]

Capítulo 3
Metodologia

Neste capítulo, serão apresentados os procedimentos metodológicos utilizados na execução da pesquisa. Primeiramente, serão apresentadas as questões de pesquisa que nortearam a pesquisa. Posteriormente, será apresentada uma proposta metodológica, que descreve os procedimentos utilizados na condução da pesquisa. Ao final, serão apresentadas as atividades realizadas para a realização da pesquisa.

3.1 Questões de Pesquisa

A primeira questão de pesquisa é: *Quais as principais funcionalidades requeridas para realizar a análise de dados?*. Esta questão foi levantada para conseuir identificar todos os requisitos necessários para o desenvolvimento do software proposto. A segunda questão é *Como desenvolver o software que atenda aos requisitos levantados?* e a terceira questão é *Como realizar a avaliação do software?*.

Para responder a primeira questão de pesquisa, foi realizada uma pesquisa de campo com os pesquisadores da área de Ciência de Dados e Processamento de sinais. A pesquisa realziada envolveu uma entrevista com a finalidade de identificar as principais funcionalidades buscadas por estes pesquisadores.

A segunda questão de pesquisa foi respondida com o auxilio da literatura, através da pesquisa bibliográfica e do emprego da engenharia de software a partir dos requisitos previamente levantados.

Já a terceira questão foi respondida com o auxilio dos pesquisadores envolvidos na pesquisa de campo, que avaliaram o software desenvolvido e proporam testes e melhorias para o mesmo.

3.2 Proposta Metodológica

Os pesquisadores selecionados para a pesquisa de campo foram os responsáveis pelo desenvolvimento do projeto SmartEnergy, que consiste em um sistema de monitoramento de consumo energia elétrica, com algortimos de aprendizado de máquina para detecção de padrões e anomalias.

Os pesquisadores foram entrevistados para determinar as principais características que o

software deveria possuir. A partir das respostas obtidas, pode ser determinados os requisitos necessários para o desenvolvimento do software. Com base nesses requisitos, o software proposto pode ser desenvolvido. Os pesquisadores envolvidos levantaram questões como *Qual a melhor forma de visualizar os dados?*, *Como integrar novos algoritmos?*, *Como exportar os resultados?*, *Como obter estatísticas númericas dos dados?*, *Qual a melhor forma de realizar a importação dos dados?*, entre outras. Todas as questões foram avaliadas e as respostas aceitas foram utilizadas para a definição dos requisitos do software.

A partir dos requisitos levantados, foi realizado a pesquisa bibliográfica para identificar projetos semelhantes e conhecer as soluções implementadas. A partir da pesquisa notamos uma variadade de softwares semelhantes, em linguagens como Java, R, Octave e MATLAB. Linguagens como estas citadas, são típicamente utilizadas por pesquisadores da área, pelo fato de já possuirem uma gama de algoritmos destinados a análise de dados já implementados.

Visto que o principal motivo para o uso das linguagens citadas é a existência de bibliotecas de algoritmos famosos já implementados, o Python foi escolhido para o desenvolvimento deste trabalho. Como já apontado anteriormente, o Python possui uma vasta bilbioteca, com uma comunidade de usuário ativa e crescente. Além disso, por possuir uma sintaxe simples, ela é ideal para que os pesquisadores, e futuros usuários, possam criar novos módulos ou plugins para extender as funcionalidades do projeto.

Por fim, a avaliação do software foi realizada com os pesquisadores. Eles propuseram a utilização e estudo de uma base de dados para avaliar a capacidade do sistema, de modo que seja satisfatório o problema proposto por ela.

[PENDENTE: Procurar base de dados]

3.3 Atividades

3.3.1 Cronograma de Atividades

A seguir é apresentado o cronograma de atividades do projeto, elaborado para que o mesmo fosse concluído no prazo, atendendo aos requisitos necessários e com a qualidade requisitada.

Quadro 1 – Cronograma de Atividades

Atividades	**Jul**	**Ago**	**Set**	**Out**	**Nov**	**Dez**
Entrevista com os Pesquisadores	X					
Pesquisa Bibliográfica		X				
Levantamento de Requisitos			X			
Documentação da Pesquisa				X		
Revisão do TCC I					X	
Defesa do TCC I						X

Fonte: O Próprio Autor (2022)

Capítulo 4
Desenvolvimento da Pesquisa

A pesquisa foi desenvolvida em duas etapas, a primeira corresponde a entrevista realizada com os pesquisadores do projeto SmartEnergy para o Levantamento de requisitos; a seguinda etapa corresponde a pesquisa bibliográfica realizada para a elaboração do TCC I, o presente trabalho.

4.1 Levantamento de Requisitos

A etapa de levantamento de requisitos foi realizada em conjunto com os pesquisadores apontados anteriormente, com o intuito de identificar as principais funcionalidades e carências para uma plataforma do tipo proposto.

O levantamento ocorreu através de entrevistas informais, onde os pesquisadores foram questionados sobre as funcionalidades que a plataforma deveria ter, e as carências que a plataforma deveria suprir. Foram apresentados base de dados, identificados os objetivos e então proposto abordagens que poderiam ser seguidas para atingir a solução.

4.1.1 Requisitos Funcionais

Os requisitos funcionais foram identificados a partir das funcionalidades que a plataforma deveria ter, e que foram apresentadas pelos pesquisadores. A seguir, são apresentados os requisitos funcionais identificados:

1. **Importação de Dados**: A plataforma deverá ser capaz de importar dados em diferentes formatos, como por exemplo, arquivos CSV, JSON, XLXS, dentre outros.
2. **Pré-processamento de Dados**: A plataforma deverá ser capaz de realizar o pré-processamento dos dados, como por exemplo, a normalização dos dados, remoção de dados faltantes, entre outros.
3. **Visualização de Dados**: A plataforma deverá ser capaz de apresentar os dados de forma visual em gráficos, em barras, gráficos de dispersão, entre outros.
4. **Processamento de Dados**: A plataforma deverá ser capaz de realizar o processamento dos dados, como por exemplo, a aplicação de algoritmos de aprendizado de máquina, como por exemplo, regressão linear, regressão logística, entre outros.

5. **Exportação de Dados**: A plataforma deverá ser capaz de exportar os dados em diferentes formatos, como por exemplo, arquivos CSV, JSON, XLXS, dentre outros.

6. **Métricas**: A plataforma deverá ser capaz de apresentar métricas de avaliação dos resultados, como por exemplo, a acurácia, a precisão, a revocação, entre outros.

7. **Extensibilidade**: A plataforma deverá ser capaz de ser estendida para novos algoritmos a partir de interfaces de código tipado e aberto.

8. **Interface de Usuário**: A plataforma deverá ser capaz de apresentar uma interface de usuário intuitiva e personalizável.

9. **Exportação de Modelos**: A plataforma deverá ser capaz de exportar os modelos de aprendizado de máquina em binários com extensão .pkl e arquivos descritivos com extensão .json.

10. **Exportação de Configurações**: A plataforma deverá ser capaz de exportar as configurações de execução em arquivos com extensão .json.

11. **Personalização de Configurações**: A plataforma deverá ser capaz de permitir a personalização das configurações de execução, como por exemplo a quantidade de iterações, a quantidade de camadas, entre outros.

12. **Extensão da Interface**: A interface da plataforma deverá ser capaz de ser estendida para novas funcionalidades preservando os estilos e funcionalidades já existentes.

4.1.2 Requisitos Não Funcionais

Os requisitos não funcionais, características que a plataforma deve possuir, mas que não são funcionalidades que o usuário precisa estar ciente, por se tratar de questões básicas de software. A seguir, são apresentados os requisitos não funcionais identificados:

1. **Execução Multiplataforma**: A plataforma deverá ser capaz de ser executada em diferentes plataformas, como por exemplo, Windows, Linux, Mac OS, entre outros.

2. **Consumo de Recursos**: A plataforma, principalmente parte que não trata do processamento, deverá ser capaz de consumir poucos recursos de hardware, como por exemplo, memória RAM, CPU, entre outros.

3. **Confiabilidade**: A plataforma deverá ser capaz de ser executada sem falhas, e em caso de falhas, deverá ser capaz de ser executada novamente sem a necessidade de intervenção humana.

4. **Desempenho**: A plataforma deverá ser capaz de ser executada em tempo hábil, sem a atrasar o processo de análise de dados.

5. **Status Operacional**: A plataforma deverá ser capaz de apresentar o status de operação, como por exemplo, se está processando os dados, salvando alterações, baixando dados, exportando gráficos ou configurações, entre outros.

6. **Log de Execução**: A plataforma deverá ser capaz de apresentar um log de execução, onde serão apresentados os eventos que ocorreram durante a execução, como por exemplo, a importação de dados, a exportação de gráficos, a exportação de modelos, entre outros.

7. **Isolamento**: A plataforma deverá ser capaz de ser executada em um container, como por exemplo, Docker, para que seja possível a execução em diferentes ambientes.

4.2 Proposta de Solução

A seguir é elaborado o conjunto de soluções para os requisitos levantados na seção anterior e que serão implementados no sistema. As soluções levantadas são exemplos de possibilidades, baseadas em estudos de caso e em experiências anteriores. A escolha da solução final será feita durante a fase de desenvolvimento do sistema, mediante a análise de custo-benefício de cada uma das soluções.

4.2.1 Interfaces de Código

Uma interface de codigo pode ser descrita como um conjunto de instruções que permitem estabelecer a conexão entre duas bilbiotecas ou ate mesmo para promover o uso de uma bilbioteca. Logo o momento da definição da interface é uma das fases mais importantes da criação de um software. [REVISAR]

Para atender os requisitos da extensabilidade, atravez da pesquisa bibliografica, as interfaces do projeto seguirão proximas as interfaces da maior bilbioteca de *Machine Learning*, o scikit-learn. A biblioteca do scikit-learn é umas das mais extensas em numero de impletementaçãos de algoritmos de aprendizado de maquina, alem de possuir uma comunidade bastante ativa. isso garante que alem da compatilibidade, não so com a propria plataforma, como simplifica a extenção das funcionalidades do software.

4.2.2 Interface Gráfica

Para o desenvolvimento deste trabalho foi selecionado com a biblioteca baseada em Qt. O Qt provem então uma serie de impletementaçãos voltadas a interface grafica de usuario, por exeplo

a criação de janelas, dialogos, entre outros. A biblioteca fornece compatilibidade com a maioria dos sistemas operacionais atuais, o que atende ao requesito não-funcional da compatilibidade como diversos sistemas operacionais.

4.2.2.1 Widgets

O PyQt é uma biblioteca baseada em *widgets*, onde cada widget corresponde a um componente exibido na janela. Os *widgets* funcionam como *wrapper's*, funções que encapsulam outra chamada, diretamente para o objeto do Qt. Os *widgets* do Qt são divididos em duas categorias: os *widgets* de controle e os *widgets* de exibição. Os *widgets* de controle são aqueles que permitem a interação do usuário com o sistema, como por exemplo, botões, caixas de texto, entre outros. Já os *widgets* de exibição são aqueles que exibem informações ao usuário, como por exemplo, tabelas, gráficos, entre outros.

Os *widgets* do PyQt são criados a partir de classes, são fácilmente extensíveis, logo é possível reutilizar e criar novos componentes para o sistema. A criação de novos *widgets* é feita através da herança, onde uma classe é criada a partir de outra, herdando seus atributos e métodos. A herança é uma das principais características da orientação a objetos, que permite a reutilização de código, reduzindo a quantidade de código a ser escrito.

As ações no PyQt funcionam em um *event loop*, onde o sistema fica em um loop infinito, aguardando por um evento. Quando um evento é disparado, o sistema sai do loop e executa a ação correspondente ao evento. Como interfaces gráficas de usuário são orientadas a eventos, a biblioteca opera através de eventos e sinais, para isso ele utiliza o conceito de *slots*. Os *slots* são funções que recebem um objeto de callback para realizar uma tarefa quando um evento acontece e um sinal é enviado.

Por exemplo, em sistema com um botão e um contador embaixo, sempre que o usuário clica no botão, o contador é incrementado. O botão envia um sinal para o slot do contador, que incrementa o contador. O sistema fica em um loop infinito, aguardando por um evento, ao clicar no botão, o sistema sai do loop e executa a ação correspondente ao evento, que é incrementar o contador.

Logo a orientação de eventos permite que o sistema seja reponsivo para o usuário, atendendo as suas ações e apresentando uma resposta visual. No projeto, essa abordagem deve atender a praticamente todas as interações do usuário para configuração dos algoritmos de aprendizado de máquina e aos métodos de visualização.

4.2.2.2 Estilização

Para solucionar a questão dos estilos padrão para toda a interface e suas extensões, será utilizado a estilização por Cascading Style Sheets (CSS), que é uma linguagem de estilização que

funciona a partir de uma série de regras que definem como os elementos da interface devem ser exibidos. A estilização por CSS permite a criação de estilos personalizados para cada elemento da interface, permitindo a criação de estilos diferentes para cada elemento através dos seletores de elemento e de classe, como por exemplo, um botão com identificador *#BackButton*, ou a estilização de caixa de texto com a classe *.Entrada*, entre outros.

Outra possibilidade é a utilização de estilos pré-definidos, como por exemplo, o *QDarkStyle* já presente na biblioteca, que fornece um estilo escuro para a interface, podendo ser utilizado para melhorar a experiência do usuário, principalmente em ambientes com pouca iluminação. Além disso também é possível utilizar biliotecas próprias para estilização da interface, que já dispõe de estilos conhecidos como o *Material Design*, que é um estilo de interface que utiliza elementos como por exemplo, sombras, bordas arredondadas, entre outros.

A estilização da interface é uma etapa importante para criar uma interface agradável para o usuário e deve ser feita de forma que corresponda às necessidades do usuário, como usar cores facilmente reconhecíveis com contraste, saturação e brilho suficientes, além de usar elementos reconhecíveis , como botões com bordas arredondadas, etc. Tudo isso oferece aos usuários uma interface intuitiva e agradável.

4.2.2.3 Gráficos

Gráficos são uma das principais formas de visualizar dados e são uma das formas mais comuns de apresentar informações aos usuários. A biblioteca *Matplotlib* e sua extensão *Seaborn* são usadas para criar gráficos que são exibidos na interface via *widget MplWidget*. Este *weidget* é uma classe herdada de *FigureCanvas* e *NavigationToolbar*, que são classes da biblioteca *Matplotlib* responsáveis por criar o gráfico e a barra de ferramentas, respectivamente.

Matplotlib é uma biblioteca gráfica que permite a criação de gráficos 2D e 3D, além de gráficos animados. Esta biblioteca é usada para criar gráficos de linhas, gráficos de barras, histogramas, etc. Já a biblioteca *Seaborn* é uma extensão do *Matplotlib* que permite a criação de gráficos melhores, com melhores estilos e cores, e além disso permite a criação de gráficos mais complexos, como gráficos de dispersão, intervalo de gráficos de linha confiável e assim sobre. A biblioteca *Seaborn* deve atender as necessidades de visualização de dados do projeto, pois permite a criação de gráficos mais complexos e com melhor estilização, além de que poderá ser facilmente extensível para a criação de novos gráficos.

4.2.3 Gerenciamento de Dados

Para solucionar a questão de gerenciamento de dados, será utilizado o *Pandas* para a manipulação dos dados, que é uma biblioteca de código aberto que fornece estruturas de dados e ferramentas de análise de dados para a linguagem de programação Python. O *Pandas* é uma

biblioteca que permite a manipulação de dados, como por exemplo, a leitura de arquivos, a criação de tabelas, a criação de gráficos, entre outros. A biblioteca *Pandas* é uma das bibliotecas mais utilizadas para manipulação de dados, pois permite a manipulação de dados de forma simples e eficiente, além de que possui uma grande comunidade de usuários e desenvolvedores.

O *Pandas* utiliza o núcleo do *Numpy*, que é uma biblioteca de código aberto que fornece suporte para arrays e matrizes multidimensionais, além de funções matemáticas para operações com esses arrays. A perfomance do *Numpy* é devido ao uso da linguagem C para a criação e operação com arrays, garantiu uma grande velocidade de processamento, além de que o *Numpy* é uma biblioteca que é amplamente utilizada em outras bibliotecas, como por exemplo, o *Tensorflow*.

Utilizando o *Pandas* é possível importar e exportar tabelas facilmente, já que a bilbiotecas já possui esses métodos. Além disso também é possível realizar operações como ordenação, filtragem, etc, tarefas básicas da análise de dados.

> Por fim, com esta proposta de solução, a plataforma será capaz de atender a maioria dos requisitos funcionais e não funcionais apresentados anteriormente. O projeto deve ser desenvolvido utilizando a linguagem de programação *Python*, que é uma linguagem de alto nível, interpretada, de tipagem dinâmica e multi-paradigma.
>
> A linguagem *Python* possui uma grande comunidade de desenvolvedores, o que facilita a obtenção de ajuda e suporte, além de ser uma linguagem de fácil aprendizado.
>
> A plataforma será desenvolvida utilizando as interfaces da biblioteca de aprendizado de máquina *Scikit-learn*, que é uma biblioteca de código aberto, de código tipado, que possui uma grande comunidade de desenvolvedores e que possui uma grande variedade de algoritmos de aprendizado de máquina.
>
> A plataforma será desenvolvida utilizando a biblioteca de visualização de dados *Matplotlib*, que é uma biblioteca de código aberto, de código tipado, que possui uma grande comunidade de desenvolvedores e que possui uma grande variedade de gráficos para visualização de dados.
>
> A interface gráfica de usuário será desenvolvida utilizando a biblioteca *PyQt*, que é uma biblioteca de código aberto, de código tipado, que possui uma grande comunidade de desenvolvedores e que possui uma ampla variedade de componentes, ou *widgets*, para a construção de interfaces gráficas de usuário.

Capítulo 5
Resultados

Com a proposta elaborada neste trabalho, é esperado a obtenção de uma plataforma capaz de integrar facilmente os dados; que seja possível extender as funcionalidades para vários algorimtos de aprendizado de máquina; além claro, da extensão da própria interface, tudo isso para que a plataforma seja capaz de atender a demanda de diversos tipos de problemas.

Em relação aos dados, a plataforma deverá oferecer a suporte a diferentes fontes de arquivos, tanto arquivos locais, quanto arquivos em nuvem, como por exemplo, o Google Drive. Além disso, a plataforma deverá ser capaz de integrar dados de diferentes tipos, como por exemplo, dados de um banco de dados relacional, dados de um aquivo de planilha como XLXS e dados de um arquivo CSV.

A plataforma também deverá integrar novos algoritmos a partir das interfaces herdadas do *scikit-learn*, como por exemplo o *Random Forest* e o *Gradient Boosting*. Além disso, a plataforma deverá ser capaz de integrar novos algoritmos de aprendizado de máquina, como por exemplo, o *Support Vector Machine* e o *Neural Network*, com a condição da utilização das interfaces compativeis. Desta forma será possível integrar novos algoritmos com poucas linhas de código.

A interface por sua vez deverá ser capaz de integrar novas funcionalidades, como por exemplo, a criação de novos tipos de gráficos, como por exemplo, gráficos de dispersão, gráficos de barras e gráficos de pizza. Além disso, a interface deverá ser capaz de integrar novas funcionalidades, como por exemplo, a integração de novos algoritmos com parâmetros personalizados, como por exemplo, o algoritmo *KNN* com o parâmetro *weights*.

Desta forma, a plataforma deverá ser capaz de atender a demanda de diversos tipos de problemas, como por exemplo, problemas de classificação, problemas de regressão e problemas de agrupamento. Seguindo os requisitos propostos, a plataforma deverá ser capaz de atender a demanda levantada no começo do trabalho com os pesquisadores do SmartEnergy.

Capítulo 6
Conclusão

A seguir serão apresentadas as conclusões do trabalho, as contribuições e limitações do mesmo, e os trabalhos futuros.

6.1 Discussão

O presente trabalho apresentou uma proposta de uma plataforma de análise e visualização de dados a ser desenvolvida em Python, atualmente uma das linguagens de programação mais utilizadas no mundo. A plataforma tem por objetivo ser fácilmmente extensivel, permitindo a adição de novos algoritmos e etapas no processo de análise de dados, além de uma interface que possa ser personalizada e modificada de forma simples.

A plataforma teve os requisitos levantados junto a um grupo de pesquisadores da área de Ciência de Dados e Processamento de sinais, que participaram do projeto SmartEnergy, esse que foi a principal inspiração para este projeto. A plataforma do SmartEnergy foi desenvolvida em Python, durante o projeto, mas não possuia os mesmos requisitos que os levantados aqui. Além disso a plataforma já existente não foi projetada seguindo padrões de projeto, o que dificultou a extensão e a manutenção do código.

Logo, a plataforma proposta no presente trabalho foi pensada para atender aos requisitos levantados, sendo suficiente para atender as necessidades do projeto SmartEnergy, e também para ser utilizada em outros projetos com problemas distintos.

6.2 Contribuições

O projeto desenvolvido neste projeto necessitou de uma extensa pesquisa bibliográfica, para que fosse possível identificar as melhores ferramentas e técnicas para a implementação da plataforma. O projeto considerou uma série de possibilidades de extensão e com foco na manutenção continua, não somente pelos desenvolvedores, mas também através da comunidade de desenvolvedores Python. Embora a arquitetura não esteja definida nesta etapa do trabalho, o projeto deverá seguir um conjunto de padrões de projeto e boas práticas de programação, para que possa ser facilmente mantido e evoluído.

Logo, o projeto contribuiu como um estudo de caso do desenvolvimento do projeto de uma plataforma de análise de dados, que pode ser utilizada como referência para plataformas com

finalidades especificas. Além disso, o projeto contribuiu com a comunidade de desenvolvedores Python, com a proposta de uso do conjunto de interfaces e bibliotecas apresentadas anteriormente.

6.3 Limitações

O trabalho apresentado possui algumas limitações, questões naturais deste tipo de projeto, como a alta variedade de tipos de dados, algoritmos e possíveis problemas que a plataforma poderá auxiliar na resolução. As limitações estão dispostas a seguir.

Devido a grande variedade de algortimos, é possível que no começo do desenvolvimento do projeto, a integração com alguns algoritmos não seja simples de tal modo como o esperado para o *scikit-learn*.

Outro ponto é que o processo de análise em *pipeline*, a organização da aplicação dos algoritmos, não será simples, devido a grande variedade de interfaces que cada algoritmo e problema dispõe. Entretando, é possível que durante a próxima etapa do projeto, seja possível identificar uma forma de organizar os algoritmos de acordo com as necessidades de cada problema abordado pelos dados.

Além disso, é possível que o desenvolvimento do projeto não seja tão simples quanto o esperado, pois o mesmo é um projeto de grande porte, que envolve diversas tecnologias e ferramentas. De todo modo, o projeto seguira o planejamento estabelecido, e será desenvolvido de acordo com os requisitos levantados.

6.4 Trabalhos Futuros

Para o futuro deste projeto é esperado que o mesmo seja desenvolvido de acordo com o planejamento estabelecido. Entretanto, é possível que durante o desenvolvimento do projeto, seja necessário realizar algumas mudanças no planejamento, devido a dificuldades encontradas durante o desenvolvimento.

Referências

Elemento Optativo para TCC I e II

Elemento Obrigatório para TCC I

APÊNDICE A

Cronograma de Atividades